

软标签蒸馏权重 α 的最优值如何随教师质量与学生容量移动

——CMExam 中文医学多选题上的三组对照消融研究（最终报告）

作者：陈天元 **单位：**珠海学院 **日期：**2026-06-22 **口径声明：**本报告所有准确率数字均出自统一的**标准化评测协议**（即下文的 canonical 评测协议，定义见第二节），三组实验、所有 α 、所有种子严格同口径，可直接横向比较。

摘要

知识蒸馏中，软标签损失的权重 α 控制"模仿教师"与"拟合标准答案"的配比：

$$\text{Loss} = \alpha \cdot \text{KL}(\text{teacher} \parallel \text{student}) + (1 - \alpha) \cdot \text{CE}(\text{标准答案}, \text{student})$$

$\alpha=0$ 是纯监督微调（只学标准答案）， $\alpha=1$ 是纯模仿教师软标签。我们在中文医学多选题数据集 CMExam（全科 7 学科，991 题主测试集）上，对三组（教师 $\times$ 学生）组合各做了完整的 α 网格消融，覆盖**教师质量**与**学生容量**两个正交维度：

组合	教师 $\rightarrow$ 学生	教师答案与标准答案不一致率	维度定位
①	DeepSeek-V3 $\rightarrow$ Qwen2.5-14B	12.2%	强教师 + 强学生（基准）
②	DeepSeek-V3 $\rightarrow$ Qwen2.5-7B	12.2%	强教师 + 弱学生（变容量）
③	Llama-3.3-70B $\rightarrow$ Qwen2.5-14B	48.4%	弱教师 + 强学生（变教师质量）

主结论：在 CMExam 这类小决策空间（5 选 1）任务上，软标签 KL 的边际价值有限，且其符号由教师质量与学生容量共同决定，规律可被预测：

- 学生越弱，最优 α 越往右移：**②（7B）最优 $\alpha=0.15$ ，①（14B）最优落在 0~0.15 平台。
- 教师越差，纯模仿崩塌越狠：**③（教师不一致 48.4%） $\alpha=0$ 最强烈最优，纯 KL（ $\alpha=1.0$ ）暴跌 -8.34pp 至 81.10%（低于无蒸馏基线）；而强教师组（①②）纯 KL 仅下降 1.3~1.6pp。

机制上，5 选 1 决策空间下软标签携带的类间信息有限，真正的增益来自决策空间监督（Choice-Head）本身，而非 Hinton 式 dark knowledge（暗知识）；教师越不可靠，模仿其软标签的代价越大。所有预先登记的预测全部命中。

一、研究背景与动机

我们已发表的 AIEA 工作 (*Choice-Head Distillation for Dental MCQ*) 证明：在 5 选 1 的答案空间内只蒸馏教师对五个选项的分布（而非全词表），可让 Qwen2.5-14B 学生超越 DeepSeek-V3 教师（best 89.10% > teacher 87.18%）。该论文主设置取 $\alpha=0.35$ ，并已定稿、不再修改。

但在固定该组合扫描 α 时，我们观察到一个反直觉现象： **α 越小（越不依赖教师软标签）准确率越高， $\alpha=0$ 附近最优，加大 KL 权重单调变差**。这立刻引出一个对审稿人致命的质疑——

这究竟是“软标签价值有限”的一般规律，还是只是 (DeepSeek-V3, 14B) 这一个组合的偶然？换个更弱的学生、或换个更差的教师，结论会不会反转？

AIEA 论文自己的局限性一节也明确写道：当前只验证了“单一强教师 + 窄学生族”，**后续工作应测试更多教师质量、更多学生规模、更多医学子域**。本报告正是为回答这个质疑、兑现这条后续工作而做。

我们沿两个正交维度各动一格，构成 L 形对照：- **沿学生容量**：学生从 14B 换成 7B (②)，教师不变；- **沿教师质量**：教师从 DeepSeek-V3（不一致 12.2%）换成 Llama-3.3-70B（在子集上不一致 48.4%），学生不变 (③)。

这样能分别隔离两个维度对“最优 α ”的影响。

二、实验设计与评测口径

2.1 标准化评测协议（canonical evaluation，全报告唯一口径）

为保证三组跨模型、跨实验严格可比，所有数字都用同一套**标准化评测协议**产出（英文文献常称 canonical evaluation，意即“作为统一基准的、规范固定的评测口径”）。它把评测全流程的四个要素一次性固定下来，任何一组实验都不得自行更改：

- 固定提示词模板**：教师生成标签与学生测试用同一套 prompt 模板；
- 固定答案抽取规则**：在闭合的五选项答案空间内做精确匹配（exact-match），不接受自由文本；
- 固定打分口径**：full 测试集 991 题为主指标，dental 子集 125 题为敏感性参照；
- 固定数据划分**：CMExam 重新划分 70/15/15，train/val/test = 4608/991/991，按难度分层。

因为四要素全程锁死，不同模型、不同 α 、不同种子跑出来的准确率才真正可比，差异只反映模型本身而非评测设置的变动。

与 AIEA 表格的关系：AIEA 表 I 的数字来自训练框架的内置评测；本报告把三组的全部 α 点都用上述标准化协议重新评了一遍，这样 ①②③ 才能无缝叠在同一张图上做横向比较。此外，本报告统一使用经过校核的单路评测器 `evaluate_model.py` 直接评测，而非早期一个存在缺陷的**双路评测脚本**（`run_eval_dual.py`，会对同一模型走两条评测路径再合并，曾因合并逻辑 bug 给出不一致的分数，故弃用）。


2.2 消融设计

- **α 网格**: {0, 0.15, 0.25, 0.35, 0.50, 0.65, 1.0}, 每个 α 跑 3 个随机种子 (11/42/8), 报告 3-seed 均值;
- **只训练 Stage-1** (Choice-Head 蒸馏头), 不接 Stage-2, 以隔离 α 的纯效应;
- **学习率**: ①③ 用 $1e-4$, ② (7B) 用 $1.2e-4$ (容量不同需单独调, 不可混用);
- **③ 的数据**: Llama 教师的可信子集 (clean_teacher, 2223 条, 教师答案与标准答案不一致率 48.4%), 软标签齐全无缺失。

教师不一致率 (教师给出的答案与标准答案不符的比例) 作为"教师质量"的天然因果代理: DeepSeek-V3 在全量训练集上不一致 12.2% (即 87.8% 答对), Llama 子集 48.4% 不一致——这是一条天然的因果梯度, 让我们能观察"教师越不可靠, 模仿它的代价如何变化"。

三、实验数据

3.1 头条核心规律图



一张图叠三条 α 曲线 (横轴 α 从纯 CE 的 0 到纯模仿的 1, 纵轴 canonical full 准确率), 空心圈标各组最优 α 。两个维度的规律一眼可见: ①② (强教师) 纯模仿端仅小幅下沉; ③ (弱教师) 在 α 增大后急剧塌方, $\alpha=1.0$ 跌到 81%。


3.2 三组完整结果 (标准化评测 full 991, 3-seed 均值, %)



α	① DeepSeek→14B	② DeepSeek→7B	③ Llama→14B
0.00	89.14	85.74	89.44
0.15	89.17	85.87	88.93
0.25	89.10	85.57	89.17
0.35	88.67	85.67	88.53
0.50	88.67	85.57	88.06
0.65	88.33	85.30	86.82
1.00	87.55	84.60	81.10

(粗体=该组最优点 / 纯 KL 端最差点。①的 $\alpha=0.15(89.17)$ 与 $\alpha=0(89.14)$ 实质并列，构成 0~0.25 平台。)

对照锚点 (来自 AIEA / 基线，均为标准化口径或可比口径)：- DeepSeek-V3 教师 full = 87.18%；Qwen2.5-14B 零样本基线 = 83.55%；Qwen2.5-7B 零样本基线 = 76.49%。- AIEA 主设置 $\alpha=0.35$ ：14B 3-seed 均值 88.67% (与本报告 ① $\alpha=0.35=88.67$ 一致)，best 单次运行 89.10%。- 旧 Llama→14B 单点实验 ($\alpha=0.35$ ，非消融)：3-seed full $\approx 87.25\%$ ，仅作背景，非本研究的 α 曲线。

3.3 三组分曲线 (full + dental 双线)





3.4 跨维度规律矩阵

组合	教师/学生	教师不一致率	最优 α	纯 KL($\alpha=1.0$) 跌幅
①	DeepSeek/14B	12.2%	0 (~0.15 平台)	-1.59pp (89.14→87.55)
②	DeepSeek/7B	12.2%	0.15 (右移)	-1.27pp (85.87→84.60)
③	Llama/14B	48.4%	0	-8.34pp (89.44→81.10, 崩塌)

四、实验结论

- $\alpha=0$ 在所有三组都不劣于任何正 α 。** 软标签 KL 在 CMExam 这类小决策空间任务上没有稳定正增益，最优配比一律落在 α 偏低端。
- 学生容量维度 (② vs ①)：** 学生从 14B 缩到 7B 后，最优 α 从 0~0.15 平台明确右移到 0.15。弱学生拟合标准答案的能力更弱，软标签的正则与平滑此时有微弱正向价值，但增益仅 +0.13pp（在 seed 噪声边缘）。7B 整体比 14B 低约 3.4pp，**全部未超过教师 87.18%**——"学生超越教师"是 14B 独有现象，受容量下限约束。
- 教师质量维度 (③ vs ①)：** 教师换成高不一致（48.4%）的 Llama 子集后， $\alpha=0$ 优势更鲜明，纯 KL 从"轻微下降"变为"彻底崩塌"——①只跌 1.59pp，③暴跌 8.34pp 到 81.10%（甚至低于无蒸馏基线 83.55%），且 $\alpha=0.65 \rightarrow 1.0$ 之间出现悬崖（86.82→81.10）。教师越不可靠，蒸馏权重越应趋零。
- 预先登记的预测全部命中。** 我们在跑实验之前就把对组合③的三条预测写定、存档、事后不再改（见文末索引的预测登记文件）：③纯 KL 崩塌远比①严重、③ $\alpha=0$ 优势更大、③ KL 惩罚曲线更陡（0.65→1.0 悬崖）——结果三条全部应验，说明规律不是事后凑出来的故事。

五、理论分析

为什么 KL 软标签在这个任务里增量这么有限？

- 决策空间太小：** CMExam 是 5 选 1。教师 softmax 在 5 个类上的分布能携带的"类间暗知识"，远少于 ImageNet 那种上千类场景。Hinton 式 dark knowledge（暗知识）的前提（丰富的类间相对相似度结构）在这里基本不成立。
- 真正的增益来自决策空间监督：** Choice-Head 把"在选项空间里做结构化决策"这件事本身教给了学生，这部分增益与 α 无关——所以 $\alpha=0$ 时性能已最好。软标签是附加项，不是主因。
- 强学生能直接拟合标准答案：** 14B 容量足够，直接用交叉熵（CE）学标准答案即可逼近上界，软标签的平滑反而引入噪声；7B 容量不足时软标签的正则价值才略显（故 ②最优 α 右移）。
- 教师可靠性决定 KL 的符号：** KL 把学生拉向教师分布。教师对 (①②) 时这是温和正则；教师错得多 (③) 时这是把学生拖向错误——所以同样加 KL，③崩、①只微降。

一句话：在小决策空间任务里，蒸馏的价值主要是"教会决策结构"而非"传递软标签暗知识"；软标签的边际价值由教师可靠性与学生容量共同决定，且常常为零或负。

六、对原有论文（AIEA）的影响

本报告与已定稿的 AIEA 论文不冲突，且在三处强化、澄清、兑现了它：

1. **兑现了 AIEA 的后续工作。** AIEA 局限性一节明确要求"测试更多教师质量、更多学生规模、更多医学子域"。本三组消融恰好沿教师质量（DeepSeek→Llama）与学生容量（14B→7B）两维补齐，把 AIEA 的单点结论扩展为有对照的规律。
2. **实证印证了 AIEA 的核心直觉。** AIEA 在方法一节写"过拟合教师标签会放大其错误（overfitting teacher labels can amplify its errors）"，但只是定性判断。③Llama 的 -8.34pp 崩塌给了这句话直接的定量证据：当教师近半数答案错误时，纯模仿确实把错误放大到崩盘。
3. **澄清了 $\alpha=0.35$ 主设置的性质。** AIEA 取 $\alpha=0.35$ 并报告 best 89.10%。标准化消融显示 $\alpha=0.35$ （88.67 均值）并非最优，真正最优在 $\alpha=0\sim0.15$ （89.14~89.17 均值）。这**不否定** AIEA 的结论（ $\alpha=0.35$ 仍显著优于基线、仍支撑"学生超越教师"），但说明：AIEA 的增益主要来自决策空间监督而非软标签，KL 权重本可更低甚至取零。被问及 α 选择时可诚实补充这一点。
4. **支撑了 AIEA 关于 Stage-2 的判断。** AIEA 称 Stage-2 硬标签校准"其有用性取决于学生容量、教师可靠性、数据规模"。本报告把这一判断量化到了 Stage-1 内部的 α 维度：最优 α 确实随学生容量（②右移）和教师可靠性（③更偏 0）系统性移动，与 AIEA 的定性表述同向。

结论：AIEA 定稿无需改动；本报告作为其后续扩展，把"软标签价值有限、决策空间监督是主因"从单组合观察升级为跨维度规律，并为 AIEA 列出的后续工作提供了完整答卷。

七、诚实边界（可质疑点逐条声明）

按"每个结论都要经得起质疑"的要求，主动列出本研究的弱点与边界：

1. **①的最优不是严格 $\alpha=0$ ，而是 $0\sim0.25$ 平台：** $\alpha=0.15(89.17)\approx\alpha=0(89.14)\approx\alpha=0.25(89.10)$ ，差异在 seed 噪声内。主张应表述为" $\alpha=0$ 不劣于任何正 α "，而非" $\alpha=0$ 严格唯一最优"。
2. **小样本方差：**dental 子集仅 125 题，单点波动可达 1~2pp，仅作敏感性参照不作主结论。③的 Llama 教师只用 2223 条可信子集，样本量小于①②的全量，跨组绝对值比较需谨慎；我们主要比较**组内 α 趋势**，趋势比绝对值稳健。
3. **单一数据集：**全部基于 CMExam（中文医学）。"小决策空间 → 软标签价值有限"的机制应能外推到其他 N 选 1 选择题任务，但**未在 CMExam 之外验证**，不宣称跨任务普适。开放域生成、大类别分类等场景结论可能不同。

4. ③的崩塌部分由子集偏置放大：48.4% 不一致是可信子集的特性，比 Llama 在全量上的不一致率更极端，放大了"弱教师"效应。它对"教师越差 KL 越有害"是有利证据，但读者应知道这是被选择强化过的对照工况，而非典型工况。
 5. 两个维度未做全因子交叉：缺"弱教师 + 弱学生" (Llama→7B) 这一格，无法分离两维度的交互项。当前是 L 形对照而非 2×2 全因子，交互效应未知。
 6. 教师不一致率作为"教师质量"代理的局限：不一致率只衡量首选答案是否对标准答案，未刻画教师 softmax 分布的校准度 (calibration)。两个不一致率相同的教师，软标签信息量仍可能不同。
 7. 学习率非完全对齐：②用 $1.2e-4$ 、①③用 $1e-4$ 。虽各自为容量调过，但严格说"学生容量维度"里混入了学习率这一干扰变量。
-

数据与脚本索引（复现用）

- 三组标准化评测原始日志：
`21_ablation/logs/{canon14b_backfill,ablation_7b_priority,ablation_llama_priority}.log`
- 绘图脚本与结构化数据：`21_ablation/scripts/make_ablation_figs.py`、
`21_ablation/figs/ablation_data.json`
- 组合③训练数据：`21_ablation/data/llama_clean2223_train.jsonl` (2223 行)
- 预测登记文件（实验前写定、存档不改）：`aiea/alpha_ablation_matrix_plan.md`；①详细结果：
`aiea/alpha_ablation_results.md`
- 原 AIEA 论文：`aiea/aiea_DentalMCQ_Distillation_2026-06-20_EN - 0030.docx`
- 旧 Llama 单点对照 ($\alpha=0.35$, 非消融, 均值 $\approx 87.25\%$):
`16_llama70b_choice_head/runs/20260416_091507_llama70b_14b/eval_results.json`