

几何深度学习未来研究方向

Choice-Head 蒸馏的几何深度学习未来研究方向

摘要

本文档从几何深度学习 / 信息几何视角，梳理 Choice-Head 蒸馏在 AIEA 比赛论文基础上的后续可行研究方向。当前 AIEA 论文已完成第一层几何化：将蒸馏目标从完整词表空间投影到五选项概率单纯形 Δ^4 。下一步最有价值的研究，不是再堆模型规模，而是回答三个核心问题：

1. 在 Δ^4 上，用什么几何距离蒸馏最好？
2. 什么样的教师分布在流形上最有「可蒸馏性」？
3. Stage 1 / Stage 2 分别对应流形上的什么操作？

本仓库毕业设计（Module 17–20）已在部分方向上完成原型实验，本文档将其与 AIEA 论文衔接，并按可行性与学术增量分级排序。

1. 核心几何对象

1.1 五选项概率单纯形

在五选项医学 MCQ 中，教师/学生的输出分布

$$p = (p_A, p_B, p_C, p_D, p_E), \quad \sum_i p_i = 1$$

是 4 维概率单纯形 Δ^4 上的点。Choice-Head 蒸馏的本质是：

- 不再在 $\mathbb{R}^{|V|}$ （完整词表 logits 空间）上做匹配；
- 而是在 Δ^4 上做 teacher-student 分布对齐。

这与 AIEA 论文的核心主张一致：对于结构化五选项考试，蒸馏目标应对齐评估时真正使用的决策空间。

1.2 从高维到决策空间的投影

完整 LLM 输出可视为高维表示空间中的点；Choice-Head 在答案位置提取五个选项 token 的 logits，再经 softmax 映射到 Δ^4 ：

$$\pi : \mathbb{R}^{|V|} \rightarrow \Delta^4$$

几何上，这是一个降维投影。AIEA 论文证明了该投影在工程与效果上的价值；尚未充分展开的是：投影丢失了什么几何信息、何种混淆模式在 hidden state 中存在但在 Δ^4 上被压扁。

1.3 与现有代码模块的对应

几何概念	项目模块	状态
α -散度族替代 KL	Module 17	已有实验
Fisher-Rao 教师标签分析	Module 18	已有分析脚本
边界距离 / 样本过滤	Module 19	已有框架
样本自适应 α 蒸馏	Module 20	已有训练脚本
流形曲率分析	manifold_curvature_analysis.py	已有脚本

2. 第一优先级：与 AIEA 论文直接衔接

以下方向实验成本相对可控，且能直接解释 AIEA 论文中已有现象（学生超过教师、Stage 2 不总是有益、seed 稳定性等）。

2.1 决策空间 α -散度蒸馏

问题：在 Δ^4 上，KL 是否是最优蒸馏度量？

Amari α -散度是 KL 的自然推广：

$$D_{\alpha}(p \parallel q) = \frac{4}{1 - \alpha^2} \left(1 - \sum_i p_i^{(1+\alpha)/2} q_i^{(1-\alpha)/2} \right)$$

α 取值	对应散度	几何特性	适用场景
$\alpha \rightarrow 1$	前向 KL	mode-seeking	当前 AIEA 基线
$\alpha = 0$	Hellinger	对称、有界	教师含噪声时更稳健
$\alpha \rightarrow -1$	反向 KL	mode-covering	保留学生多样性

已有证据（Module 17）：在相同超参下， $\alpha = 0.5$ 与 Hellinger 均值 74.10%，优于标准 KL 的 72.29%；KL 的 seed 敏感性最大 ($\Delta = 4.82$ pp)。

可行实验：

- 在 991 题全量测试集上复现 $\alpha \in \{-1, 0, 0.5, 1\}$ sweep (7B / 14B)
- 报告均值、最优、seed 极差，与 AIEA Table 1 对齐
- 讨论：Hellinger 是否在「教师-GT 不一致率 12.2%」的设置下更稳健

预期贡献：将 AIEA 的「换 loss」提升为「决策流形上几何度量选择」的系统性结论。

2.2 Fisher-Rao 距离与软标签可蒸馏性

问题：两个教师都选对时，几何形状不同，蒸馏效果为何不同？

Fisher-Rao 距离 (Δ^4 上的黎曼测地线距离)：

$$d_{\text{FR}}(p, q) = 2 \arccos \left(\sum_{i=1}^5 \sqrt{p_i q_i} \right)$$

直觉示例 (硬标签相同，流形位置不同)：

- 教师 A：(0.96, 0.01, 0.01, 0.01, 0.01) — 高置信、靠近单纯形顶点
- 教师 B：(0.56, 0.24, 0.10, 0.06, 0.04) — 保留混淆结构、靠近单纯形内部

已有证据 (Module 18)：FR→GT 距离、熵、peak probability 可区分强/弱教师；假软标签 (smooth_eps) 在几何上「扁平」、信息密度低。

可行实验：

- 对 DeepSeek-V3 训练标签做 FR→GT、边界距离、熵的分布统计
- 按几何特征分桶 (高置信 / 边界样本 / 高熵样本)，分析蒸馏增益
- 检验：FR 几何特征能否预测「学生超过教师」或「Stage 2 是否有益」

预期贡献：为 AIEA 论文「学生超过教师」提供几何解释，而非仅报告准确率。

2.3 样本自适应 α ：流形区域决定局部度量

问题：能否根据样本在 Δ^4 上的位置，动态选择散度？

策略 (Module 20 原型)：

$$\alpha_i = f(d_b(p_T^{(i)}, \text{GT}))$$

- 教师自信 (d_b 小，靠近顶点) → α 接近 1，用 KL 精确学习
- 教师犹豫 (d_b 大，靠近边界或内部) → α 接近 0，用 Hellinger 稳健学习

可行实验：

- 在 991 题设置上对比固定 KL vs 自适应 α
- 重点观察：Stage 2 需求是否随 d_b 分布变化而减少

- 分析：自适应策略是否降低 seed 敏感性

预期贡献：把「Stage 2 是条件性校准」形式化为流形上的区域自适应操作。

2.4 几何感知的条件 Stage 2

问题：AIEA 论文已指出 Stage 2 不总是有益——能否用几何准则决定是否启用？

假设：

- Stage 1 已在 Δ^4 上完成结构注入（相对偏好图）
- Stage 2 是沿 gold label 方向的硬投影；当学生已在正确区域时，硬投影可能破坏软结构

可行规则：

- 仅当 $d_{\text{FR}}(p_S, \text{GT}) > \tau$ 或 $d_b(p_T) > \tau$ 时启用 Stage 2
- 或仅对 7B 弱学生启用，14B 强学生跳过

预期贡献：将 AIEA Section IV 的 Stage 2 讨论升级为可操作的几何触发策略。

3. 第二优先级：流形投影与优化几何

以下方向学术深度更高，适合期刊扩展版或毕业设计深化章节。

3.1 词表空间 $\rightarrow \Delta^4$ 的投影信息损失

研究 $\pi : \mathbb{R}^{|V|} \rightarrow \Delta^4$ 的信息损失：

- 比较 option-level logits 与 full-vocab logits 的互信息
- 分析 hidden state 中哪些混淆维度在投影后被丢弃
- 探索「可学习的决策子空间基」，替代固定 A/B/C/D/E token

3.2 自然梯度 / 黎曼优化

在 Δ^4 上使用 Fisher 信息矩阵定义自然梯度，替代欧氏空间中的普通 CE/KL 梯度。

可验证问题：

- 收敛速度是否提升
- seed 稳定性是否改善
- 是否减少对 Stage 2 的依赖

3.3 教师-学生测地线插值

在 Δ^4 上沿 Fisher-Rao 测地线定义插值路径 $p(t)$, 研究：

- GT $\rightarrow$ teacher $\rightarrow$ student 的最优路径
- Stage 1 / Stage 2 是否对应流形上两段不同轨迹
- 测地线长度是否与蒸馏增益相关

3.4 流形曲率与训练动力学

利用 `manifold_curvature_analysis.py` 分析：

- 高曲率样本是否更易导致 Stage 2 过校准
- 「学生超过教师」是否集中在低曲率、结构清晰区域
- 教师标签在 Δ^4 上是否形成可聚类的几何模式

4. 第三优先级：更广的几何深度学习扩展

适合作为长期研究线，不建议全部塞进 AIEA 4 页稿。

4.1 最优传输 (OT / Wasserstein) 蒸馏

在 Δ^4 上用 Wasserstein 距离替代 KL：

- 更对称、更几何
- 多教师融合：Wasserstein barycenter 优于简单平均
- 解释弱教师仍可提供有效几何信号

4.2 题目-选项图上的几何深度学习

构建医学 MCQ 图结构（题目、选项、知识点为节点），用 GNN / graph diffusion 传播结构信息，再蒸馏到 Δ^4 。从「单样本单纯形」扩展到「样本集合上的几何结构」。

4.3 双曲几何嵌入医学层级知识

医学概念具有层级结构（疾病 $\rightarrow$ 症状 $\rightarrow$ 检查 $\rightarrow$ 治疗）。可在 Poincaré 球等双曲空间中嵌入题目与选项，在双曲空间做 teacher-student 对齐，再映射回 Δ^4 做最终选择。

5. 建议写入 AIEA 论文 Future Work 的三条

若篇幅有限（4 页 IEEE），建议 Future Work 只保留以下三条，与正文结论直接呼应：

- 1. **Decision-space α -divergence distillation**
在 Δ^4 上系统比较 KL / Hellinger / reverse KL，解释 seed 稳定性与教师噪声鲁棒性。
- 2. **Fisher-Rao teacher label analysis**
用 FR 距离、边界距离、熵解释「学生为何能超过教师」以及「Stage 2 何时有害」。
- 3. **Geometry-aware conditional calibration**
将 Stage 2 改为流形上的条件操作：仅在高不确定区域做 gold-answer 投影，而非全局 SFT。

6. 实验路线建议

阶段 A（1–2 周，低成本）

任务	模块	输出
α -散度 sweep（991 题）	Module 17 扩展	对比表 + seed 稳定性
FR 标签分布统计	Module 18	几何特征 vs 准确率相关图
边界距离分桶分析	Module 19	Stage 2 增益条件报告

阶段 B（2–4 周，中成本）

任务	依赖	输出
样本自适应 α 全量实验	Module 20	14B 最优配置更新
几何触发 Stage 2	AIEA 结论	条件校准策略
投影信息损失分析	hidden states	1 段 Discussion

阶段 C（长期）

- OT 多教师融合
- 图结构 + 双曲嵌入
- 自然梯度训练

7. 关键公式速查

概率单纯形：

$$\Delta^4 = \left\{ p \in \mathbb{R}^5 : p_i \geq 0, \sum_i p_i = 1 \right\}$$

Fisher-Rao 距离：

$$d_{\text{FR}}(p, q) = 2 \arccos \left(\sum_i \sqrt{p_i q_i} \right)$$

α -散度：

$$D_\alpha(p \parallel q) = \frac{4}{1 - \alpha^2} \left(1 - \sum_i p_i^{(1+\alpha)/2} q_i^{(1-\alpha)/2} \right)$$

Choice-Head 学生分布：

$$p_S = \text{softmax}(z_S[t_A, t_B, t_C, t_D, t_E])$$

Stage 1 损失（AIEA 基线）：

$$\mathcal{L}_{\text{stage1}} = \alpha \cdot D_{\text{KL}}(p_T \parallel p_S) + (1 - \alpha) \cdot \mathcal{L}_{\text{CE}}$$

8. 参考文献（几何相关）

1. S. Amari, *Information Geometry and Its Applications*. Springer, 2016.
2. C. R. Rao, “Information and the accuracy attainable in the estimation of statistical parameters,” *Bull. Calcutta Math. Soc.*, 1945.
3. J. Gou et al., “Knowledge distillation: A survey,” *IJCV*, 2021.
4. G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” NIPS Workshop, 2015.

9. 总结

层级	核心问题	代表方向	与 AIEA 关系
第一层（已完成）	蒸馏应对齐决策空间	Choice-Head on Δ^4	AIEA 正文
第二层（近期）	用什么几何距离	α -散度、FR 分析	Future Work / 期刊扩展
第三层（中期）	流形上如何优化	自然梯度、测地线、曲率	毕业设计深化
第四层（长期）			独立后续论文

层级	核心问题	代表方向	与 AIEA 关系
	结构化医学知识 几何	OT、GNN、双 曲嵌入	

一句话结论：AIEA 论文完成了「在 Δ^4 上蒸馏」；下一步最有价值的，是研究「在 Δ^4 上如何蒸馏、何时校准、哪些教师标签在流形上真正可蒸馏」。Module 17–20 已提供实验基础，可按阶段 $A \rightarrow B \rightarrow C$ 逐步推进。

文档维护：*mentalDistill* / *aiea* 目录