

基于知识蒸馏的牙科选择题自动答题系统

Table of Contents

基于知识蒸馏的牙科选择题自动答题系统

A Knowledge Distillation-Based Automatic Dental Multiple-Choice Question Answering System

陈天元 (CHEN TIANYUAN)

学生编号：256360231

资讯科学学系 (Department of Computer Science)

硕士论文（满足学位部分要求）

应用人工智能理学硕士 (Master of Science in Applied Artificial Intelligence)

香港珠海学院 (HONG KONG CHU HAI COLLEGE)

导师姓名（职称）：熊体超博士（副教授）

Supervisor: Dr. Richard Tai-Chiu Hsung (Associate Professor)

日期：MAY 2026

学位论文独创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下独立完成的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律效力。

学位论文作者签名：_____

日期：____年__月__日

学位论文版权使用授权声明

本学位论文作者完全了解香港珠海学院有关保留、使用学位论文的规定，即：学校有权保留并向有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。

学位论文作者签名：_____ 导师签名：_____

日期：____年__月__日 日期：____年__月__日

摘要

牙科智能问答若要真正服务患者教育与分诊辅助，关键问题不在于模型是否足够大，而在于高性能能力能否以可承受的成本完成部署。针对这一问题，本文以牙科医学选择题自动答题为研究对象，采用知识蒸馏（Knowledge Distillation, KD）方法，将大型教师模型的判别能力迁移到较小的学生模型，以同时兼顾准确率、部署成本与可复现性。

基于中国医师资格考试数据集 CMExam，本文构建了牙科选择题评测基准，并提出面向五选一任务的 Choice-Head 两阶段蒸馏框架。该方法不再对全词表 logits 进行蒸馏，而是直接学习 A/B/C/D/E 五个候选选项上的概率分布，因此既能兼容黑盒 API 教师，也能显著降低显存与计算开销。围绕该框架，本文完成了 21 组系统性实验，并得到四项核心结论：第一，Qwen2.5-14B 学生模型在 991 题全量测试集上达到 89.10% 最佳准确率，3-seed 均值为 88.67%，超过 DeepSeek-V3 教师的 87.18%，说明在 45 倍参数压缩条件下仍可实现性能反超；第二，教师质量与蒸馏收益呈倒 U 型关系，教师与标准答案不一致率位于 5%-15% 区间时效果最佳；第三，基于 Fisher-Rao 距离与 α -散度的分析表明，真实 logprobs 标签较人工平滑标签保留了更丰富的连续结构信息，其体积密度高约 2500 倍；第四，异构教师同样可以提供有效蒸馏信号，72.8% 准确率的 Llama-3.3-70B 教师仍能蒸馏出达到 87.25% 的 14B 学生模型。

本文结果表明，围绕任务决策结构设计蒸馏目标，是推动医疗大模型轻量化落地的一条可行路径。Choice-Head 框架不仅适用于本研究的牙科场景，也为其他标准化多选知识评测任务提供了可迁移的方法参考。

关键词：知识蒸馏；大语言模型；牙科人工智能；选择题自动答题；Choice-Head 蒸馏；信息几何；Fisher-Rao 距离；LoRA 微调

Abstract

For dental question answering to be practically used in medical education and triage support, the key issue is not simply model size, but whether high performance can be deployed at an acceptable cost. To address this problem, this study treats dental medical answering as a measurable proxy task and uses knowledge distillation (KD) to transfer decision ability from large teacher models to smaller student models while balancing accuracy, efficiency, and reproducibility.

Based on the Chinese Medical Examination dataset CMExam, this study builds a dental multiple-choice benchmark and proposes a Choice-Head two-stage distillation framework tailored to five-option questions. Instead of distilling full-vocabulary logits, the framework directly learns the probability distribution over options A/B/C/D/E, which both preserves task-relevant supervisory signals and remains compatible with black-box API teachers while substantially reducing memory overhead. Across 21 systematic experiments, four main findings are obtained. First, a Qwen2.5-14B student reaches 89.10% best accuracy on the 991-question full test set, with an 88.67% three-seed mean, exceeding the DeepSeek-V3 teacher's 87.18% under 45 $\times$ parameter compression. Second, teacher quality shows an inverted-U relationship with distillation gain, with the best signal appearing when the teacher-GT disagreement rate falls between 5% and 15%. Third, analyses based on Fisher-Rao distance and the α -divergence family show that real logprobs retain much richer continuous structure than manually smoothed labels, with approximately 2,500 times higher volume density. Fourth, useful distillation remains possible across architectures: a Llama-3.3-70B teacher with only 72.8% accuracy can still produce a 14B student reaching 87.25%.

Keywords: Knowledge Distillation; Large Language Model; Dental Artificial Intelligence; Multiple-Choice Question Answering; Choice-Head Distillation; Information Geometry; Fisher-Rao Distance; LoRA Fine-tuning

缩写

英文全称

中文释义

LLM

Large Language Model

大语言模型

KD

Knowledge Distillation

知识蒸馏

SFT

Supervised Fine-Tuning

监督微调

LoRA

Low-Rank Adaptation

低秩适配

KL

Kullback-Leibler (Divergence)

KL 散度

CE

Cross-Entropy

交叉熵

MCQ

Multiple-Choice Question

选择题

GT

Ground Truth

标准答案/真值

CoT

Chain-of-Thought

思维链/推理链

NLP

Natural Language Processing

自然语言处理

API

Application Programming Interface

应用程序接口

MoE

Mixture of Experts

混合专家模型

FR

Fisher-Rao (Distance)

Fisher-Rao 距离

PEFT

Parameter-Efficient Fine-Tuning

参数高效微调

BF16

Brain Floating Point 16

脑浮点 16 位精度

AWQ

Activation-aware Weight Quantization

激活感知权重量化

GPU

Graphics Processing Unit

图形处理单元

GQA

Grouped Query Attention

分组查询注意力

PP

Percentage Point

百分点

第一章 绪论

1.1 研究背景

在医疗健康领域数字化转型的浪潮中，牙科作为与民众日常生活密切相关的细分领域，其信息服务的便捷性与专业性需求日益凸显。传统牙科咨询模式高度依赖线下门诊与专业医师的人工响应，受诊疗时间、地域分布、医师资源等因素限制，难以满足患者对牙科健康知识的即时性、常态化查询需求。近年来，以 GPT 系列、LLaMA、Qwen 为代表的预训练大语言模型相继涌现，在文本理解生成和推理等任务上取得了突破性进展。在医疗领域，这些模型通过在大规模医学语料上进行预训练和微调，展现出对医疗专业文本的深度理解能力和高质量生成能力。

然而，当前商业级大语言模型的部署面临显著的资源瓶颈。以 DeepSeek-V3 为例，该模型拥有 671B 参数（稀疏混合专家架构，每次推理激活约 37B 参数），虽然在中国医师资格考试（CMEExam）牙科科目上达到了 87.95% 的准确率，但其推理需要大量 GPU 算力支持，单卡显存需求 40-90GB，API 调用也产生持续费用。对于基层医疗机构和个人开发者而言，直接部署这些大模型既不经济也不现实。知识蒸馏（Knowledge Distillation, KD）技术为解决这一矛盾提供了可行路径：通过将大型教师模型的知识迁移至参数量远小的学生模型，在保持可接受性能水平的同时，大幅降低推理成本和硬件需求。

1.2 研究动机

本研究的动机并非单纯追求更高的离线答题分数，而是试图回答一个更接近应用落地的问题：牙科知识服务能否在资源受限条件下获得足够可靠的模型能力。围绕这一问题，本文的研究动机可归纳为三个相互关联的现实约束。

首先，牙科信息服务存在明显的可及性缺口。许多常见口腔问题并不一定需要患者立即进入诊疗流程，但患者往往缺少对症状、风险与就诊时机的基础判断依据。线下咨询受门诊时间、地区资源和医生工作负荷限制，难以持续提供低门槛、即时性的解释型信息服务。因此，一个面向牙科场景的智能问答系统不仅是技术尝试，也有明确的公共服务价值。

其次，现有高性能模型的使用门槛与部署成本过高。无论是本地运行所需的高端 GPU、显存与维护成本，还是商业 API 的持续调用费用，都使得先进模型很难直接下沉到基层机构、教学演示或隐私敏感环境。换言之，当前最强模型可以作为能力上界，却未必适合作为最终交付形态，这就要求研究寻找一种低成本继承教师能力的技术路径。

最后，通用蒸馏方案与本任务之间存在方法错位。牙科考试数据是标准化五选一选择题，而传统蒸馏通常围绕全词表 logits 或自由文本生成展开，既带来高维冗余，也难适配 API 教师不可见内部状态的现实条件。与其在通用方案上做高成本折中，不如直接围绕选择题的决策结构设计蒸馏目标，从任务头层面提取更紧凑、也更可获得的监督信号。这一观察直接促成了本文后续的 Choice-Head 蒸馏框架。

1.3 研究目标

本研究的总体目标，是构建一套面向牙科患者教育与分诊辅助场景的轻量化智能问答方案。具体而言，本文希望通过知识蒸馏把大型教师模型的医学判别能力迁移到较小的学生模型，使其在 45 倍以上参数压缩条件下仍保持接近甚至超越教师的答题性能，并具备在普通 GPU 设备上部署的可行性。

围绕这一总体目标，本文设置了四项具体任务：（1）基于 CMExam 数据集建立标准化牙科选择题评测基准；（2）设计并验证 Choice-Head 蒸馏框架，使其同时兼容黑盒 API 教师与白盒本地教师；（3）分析学生模型在不同教师、不同训练阶段和不同数据规模下的性能变化，并验证学生超越教师的条件；（4）实现可交互的牙科问答原型系统，为后续教学演示与应用落地提供接口基础。

1.4 研究贡献

本研究历时约两个月（2026 年 3 月至 4 月），在 NVIDIA H100 NVL 95GB GPU 上完成 21 组系统性实验。相较于单一方法验证，本文更强调从任务设计、经验规律到理论解释的完整闭环。综合来看，研究贡献主要体现在以下五个方面。

第一，提出了适配标准化选择题的蒸馏框架。本文将蒸馏监督从全词表 logits 缩减为选项级概率分布，使蒸馏目标与五选一任务的最终决策保持一致。该设计既适用于白盒本地教师也适用于只能提供选项概率信息的 API 教师，并将典型显存需求从约 90GB 压低到约 22GB。

第二，验证了轻量学生模型在真实评测中的性能上限。实验表明，Qwen2.5-14B 学生在 991 题全量测试集上取得 89.10% 的最佳准确率，3-seed 均值为 88.67%，高于 DeepSeek-V3 教师的 87.18%。这一结果说明，蒸馏并不只是“尽量接近教师”，在合适的数据与训练设置下，学生仍有可能获得超过教师的任务表现。

第三，识别了教师质量与蒸馏收益之间的非线性规律。通过多种强弱教师的对照实验，本文发现蒸馏效果并不随教师准确率单调提升，而更依赖教师输出中可迁移的混淆结构。与其关注教师绝对分数，更有效的指标是教师与 GT 之间的偏离程度及其所携带的判别信息。

第四，补充了对蒸馏标签质量的几何解释。本文引入 Fisher-Rao 距离与 α -散度家族，对真实 logprobs 和人工平滑标签在概率流形上的差异进行分析，为解释弱教师失败、假软标签收益有限等现象提供了更具结构性的证据。

第五，说明了框架对教师架构差异具有一定鲁棒性。即使教师并非 Qwen 同系模型，Choice-Head 蒸馏仍能迁移有价值的决策信号。以 Llama-3.3-70B 为教师时，所得 14B 学生达到 87.25% 的均值准确率，证明该方法并不依赖单一模型家族。

1.5 研究计划与技术路线调整

本研究的实际执行时间线可分为两个阶段。

上学期（2025 年秋季学期，第 4-12 周）以技术预研与数据准备为主：第 4-5 周调研医疗大模型并收集 Huatuo26M-Lite 数据集；第 7-9 周系统学习知识蒸馏方法，包括 Hinton 软标签蒸馏、FitNets 和注意力转移，并研究 MiniMind 开源框架；第 10-11 周完成中期报告，初步抽取 3,223 条牙科相关数据并建立早期评估方案。

下学期（2026 年春季学期，第 1-14 周）转入核心实验与论文撰写：第 1-2 周完成技术路线转型，从 Huatuo26M/MiniMind 切换到 CMExam/自研蒸馏框架，并搭建 H100 实验环境；第 3-10 周依次完成基线、单教师蒸馏、多教师融合、自蒸馏、CoT 蒸馏、学生容量升级、全量数据验证、跨架构蒸馏与信息几何实验；第 11-14 周集中进行论文整理、修订和答辩准备。

技术路线的调整是本研究成功的关键。早期方案基于 Huatuo26M-Lite 开放式问答数据和 MiniMind 蒸馏框架，但实践中暴露出三个问题：其一，开放式问答答案质量参差不齐，难以建立精确、可重复的量化评估；其二，MiniMind 更适合从零训练小模型，与本研究“从大模型向中等规模学生模型蒸馏”的目标不完全匹配；其三，部分候选医疗模型和旧框架存

在明显的依赖兼容性与维护问题。转向 CMExam 选择题数据集后，评估指标统一为精确匹配准确率，实验设计、结果比较和复现性都显著改善。

1.6 论文结构

本论文正文共五章，另附参考文献、附录与致谢。第一章为绪论，介绍研究背景、动机、目标和贡献。第二章为研究背景与理论基础综述医疗人工智能聊天机器人、知识蒸馏和医疗大语言模型的研究现状，并介绍相关理论基础。第三章为设计与方法，详细阐述 Choice-Head 两阶段蒸馏框架的设计与实现。第四章为实验结果与分析，汇报 21 组实验的详细结果并进行系统性分析。第五章为讨论与结论，总结研究贡献、讨论局限性并提出未来工作方向。

第二章 研究背景与理论基础

2.1 医疗人工智能聊天机器人研究现状

医疗问答与医疗聊天系统的发展，反映了自然语言处理技术从通用文本处理走向专业健康服务的演进路径。就现有工作而言，相关研究大体可以分为两类：一类面向覆盖范围较广的通用医疗咨询，另一类则围绕特定专科任务进行定向适配。

在通用医疗场景中，研究者多基于大型预训练语言模型（如 GPT 系列、ChatGLM、LLaMA 等），通过医疗领域数据集监督微调（Supervised Fine-Tuning, SFT），实现疾病咨询、用药指导、健康科普等基础功能。现有中文医疗对话模型普遍强调医患交互中的专业性、可理解性与人性化表达；HuatuogPT 则以创新的训练方法论和强大的医学推理能力为亮点，支持多尺度模型选择。

在垂直专科场景中，研究者针对特定医学领域的需求特点优化模型的专业适配性。在牙科聊天机器人方向，目前的研究相对有限。已有研究基于 ChatGLM3 预训练模型，采用 Huatuo26M-Lite 数据集中的牙科子集进行微调，验证了专科数据对模型性能提升的关键

作用，但该研究存在数据规模与多样性不足的问题，未能充分挖掘专科场景的复杂需求。此外，该研究使用开放式问答评估，评估指标的量化程度有限。

近年来，医学大语言模型的评测基准也取得了重要进展。CMExam 收录了中国执业医师资格考试真题，涵盖多个临床学科，以标准化选择题形式提供客观、可量化的评估方案。

MedQA 和 PubMedQA 等英文数据集也为医疗 AI 的性能评估提供了标准化基准。本研究选用 CMExam 的牙科子集作为评测基准，既保证了题目的专业性和权威性，又支持精确匹配准确率的主观评估。

2.2 知识蒸馏技术研究进展

知识蒸馏最初被提出时，核心目标是让小模型在较低部署成本下继承大模型的判别能力。对本研究而言，蒸馏并不是一个抽象的模型压缩工具，而是连接“强教师可用”与“轻学生可部署”之间落差的关键方法。其价值不只体现在最终准确率接近教师，更在于教师输出分布中包含的相对偏好信息能够为学生提供比单一正确标签更丰富的训练信号。

从方法演化来看，早期蒸馏工作主要强调概率分布匹配。Hinton 的软标签蒸馏通过温度缩放让教师分布更平滑，使学生能够学习类别之间的相似性结构，而不仅仅是硬标签对应的单点监督。随后出现的 FitNets、Attention Transfer 等方法，则分别从中间层表示和注意力模式出发，说明蒸馏可以发生在不同层级的信息表达上。这些工作共同奠定了一个基本判断：学生真正需要继承的并非单一答案，而是教师对候选空间的组织方式。

当蒸馏进入自然语言处理场景后，DistilBERT 进一步证明了蒸馏不仅可以作为任务微调阶段的压缩手段，也可以直接作用于预训练语言模型本身，从而在保持较强通用性的同时显著缩小模型体量。TextBrewer 则把蒸馏过程进一步工程化，展示了任务蒸馏、教师适配和训练流程编排可以被统一到可复用工具链中。这两类工作说明，在大语言模型时代，蒸馏问题不仅是损失函数设计问题，也是训练工作流设计问题。

但当蒸馏对象从图像分类网络转向大语言模型时，经典方案会立刻遇到任务与系统层面的双重约束。第一，词表规模膨胀使全 vocab logits 的存储与计算代价迅速上升，例如 Qwen2.5 的输出空间已达到 151,936 维。第二，许多高性能教师以 API 形式存在，外部研究者无法稳定获得完整内部状态，传统白盒蒸馏因此失去适用前提。第三，大语言模型通常服务于具体任务场景，不同任务对蒸馏信号的需求差异很大，通用式蒸馏目标未必最有效。在这种背景下，任务结构本身就成为重新定义蒸馏目标的依据。对于五选一医学选择题，教师真正需要传递给学生的信息并不在于完整词表上的概率细节，而在于五个候选项之间的相对支持关系。只要能够恢复这种选项级分布，无论教师来自本地模型还是 API 服务，都有可能形成有效监督。本文提出的 Choice-Head 蒸馏正是沿着这一思路，将蒸馏问题从通用 token 分布匹配改写为任务头层面的决策分布迁移。

与此同时，参数高效微调也为蒸馏提供了现实可行的训练载体。LoRA (Low-Rank Adaptation) 通过低秩增量参数完成大模型适配，使训练成本维持在可控范围内。将 LoRA 与蒸馏结合，意味着学生既能够接收教师提供的软标签结构信息，又不需要承担全量参数更新带来的硬件负担，这也是本文实验体系能够快速迭代的重要前提。

2.3 医疗大语言模型发展现状

医疗大语言模型的发展推动了医疗 AI 的工业化落地，当前已涌现出多个各具特色的开源和商业模型。

通义千问系列 (Qwen) 是阿里云推出的模型系列，提供了 7B、14B、32B、72B 等多种规模的模型，在中文医疗场景中表现突出。Qwen2.5-7B-Instruct 在 CMExam 牙科测试集上的零样本准确率为 77.11%，14B 版本提升至 83.13%。其稠密 Transformer 架构、152,064 维词表和分组查询注意力 (GQA) 设计在中文文本处理上具有优势。Qwen3 系列引入了推理链 (thinking/non-thinking) 双模式设计，专为 Chain-of-Thought 推理优化。

从更底层的结构组件看，现代 Qwen、LLaMA 等主流模型普遍采用 Rotary Position Embedding (RoPE) 这一位置编码路线，其直接理论源头可追溯到 RoFormer 对旋转式

相对位置编码的系统化提出。这类设计使长上下文中的相对位置信息能够更平滑地融入自注意力计算，也是本文所使用各类 Transformer 学生/教师模型共享的重要结构背景。

DeepSeek 系列中，DeepSeek-V3 采用稀疏混合专家（Mixture of Experts, MoE）架构，总参数量 671B，每次推理仅激活约 37B 参数，在多个基准测试中达到与 GPT-4 级别的性能。在 CMExam 牙科测试集上准确率为 87.95%，是本研究的主要教师模型。

Meta LLaMA 系列中，Llama-3.3-70B-Instruct 是 Meta 发布的高性能开源模型，采用稠密 Transformer 架构。虽然在中文医学任务上的表现弱于 Qwen 和 DeepSeek（CMExam 准确率约 72.45%），但其完全异构的架构为跨架构蒸馏验证提供了理想的实验对象。

豆包（Doubao）是字节跳动推出的推理模型，在 CMExam 牙科测试集上达到 98.80% 的最高准确率，但其参数规模和技术细节未公开。本研究中豆包作为高性能教师模型之一参与蒸馏实验。

Kimi（月之暗面推出，moonshot-v1-32k）在牙科测试集上仅达到 61.45% 的准确率，作为本研究的弱教师负例提供了重要的对比参照。

为了更直观地说明本文实验中教师与学生之间的容量差异，表 2-1 汇总了本研究涉及的主要模型参数规模。可以看到，已公开的模型规模从 7B 学生到 671B 总参数的

DeepSeek-V3 教师不等；对于豆包与 Kimi 等闭源 API 模型，由于官方未披露参数规模，本文仅将其作为黑盒教师使用，而不将其纳入严格的公开参数对比。

模型

角色

参数规模

备注

Qwen2.5-7B-Instruct

学生模型

7B

7B 主力学生，也用于自蒸馏实验

Qwen2.5-14B-Instruct

学生模型 / 对照教师

14B

14B 主力学生，在 Module 05 中也作为同容量教师对照

Qwen3-14B

学生模型

14B

用于跨架构/新架构学生对照

Qwen2.5-32B-Instruct

教师模型

32B

本地白盒教师，可直接读取 logits

Llama-3.3-70B-Instruct

教师模型

70B

异构开源教师，用于跨架构蒸馏

DeepSeek-V3

教师模型

671B 总参数 / 37B 激活参数

MoE API 教师，本文主要高性能教师

Doubao

教师模型

未公开

商业 API 教师，仅能按黑盒方式使用

Kimi (moonshot-v1-32k)

教师模型

未公开

商业 API 教师，作为弱教师负例

2.4 信息几何理论基础

信息几何 (Information Geometry) 是由 Amari 等人发展的数学理论，将概率分布族视为黎曼流形，利用微分几何工具研究统计模型的内在结构。近年来，信息几何在机器学习领域的应用日益广泛。

在 n 类分类任务中，模型的输出概率分布 $p = (p_1, p_2, \dots, p_n)$ 构成一个 $(n-1)$ 维概率单纯形。Fisher 信息度量 $g_{ij}(p) = \delta_{ij}/p_i$ 赋予该单纯形一个黎曼结构。Fisher-Rao 距离定义为：

$$d_{FR}(p, q) = 2 \arccos \left(\sum_i \sqrt{p_i q_i} \right)$$

Amari 的 α -散度是 KL 散度的自然推广：

$$D_\alpha(p \parallel q) = \frac{4}{1-\alpha^2} \left(1 - \sum_i p_i^{(1+\alpha)/2} q_i^{(1-\alpha)/2} \right)$$

当 $\alpha \rightarrow 1$ 时退化为前向 KL 散度 (mode-seeking), $\alpha=0$ 时正比于 Hellinger 距离的平方 (对称、有界), $\alpha \rightarrow -1$ 时退化为逆向 KL 散度 (mode-covering)。不同 α 值对应不同的几何特性, 在蒸馏中产生不同的梯度行为。

在知识蒸馏中, 教师和学生的输出分布都是概率单纯形上的点。蒸馏损失函数 (通常为 KL 散度) 实际上是在 Fisher 流形上定义的距离度量。本研究创新性地将信息几何理论应用于蒸馏标签质量分析, 通过 Fisher-Rao 距离、流形曲率和边界距离等几何特征, 定量揭示了不同类型教师标签 (人工平滑 vs 真实 logprobs) 的本质差异。

2.5 技术路线总览

本研究采用逐层推进的实验路线, 而非一次性固定方案。整体流程可以概括为四个阶段: 首先完成数据准备与 GT SFT 基线建立, 明确学生模型在无蒸馏条件下的初始能力; 随后分别开展白盒 Logit-KL 蒸馏与黑盒 Choice-Head 蒸馏, 对比不同教师形态下的知识迁移效果; 在此基础上继续扩展到多教师融合、自一致性过滤、CoT 蒸馏以及学生容量升级, 判断哪些策略真正带来稳定收益; 最后再通过全量数据重分割、跨架构蒸馏和信息几何分析, 对前述经验结论做更大样本和更强解释层面的验证, 并完成面向演示的 Web 系统部署。

第三章 设计与方法

3.1 系统配置

3.1.1 硬件环境

本研究全部实验在以下硬件平台上完成: GPU 为 NVIDIA H100 NVL 95GB, 精度为 BF16 混合精度训练。典型训练显存方面, 7B LoRA 约 22GB, 14B LoRA 约 35GB。白盒蒸馏显存约 90GB

(32B 教师 + 7B 学生同时加载)。Llama-70B-AWQ 推理约 38GB (vLLM, INT4 量化)。

3.1.2 软件环境

操作系统为 Linux (Ubuntu) , Python 为 3.13 (Anaconda) , PyTorch $\geq 2.0.0$, Transformers $\geq 4.30.0$, PEFT $\geq 0.18.0$, vLLM 0.16.0 (用于 Llama-70B 本地推理), Gradio 用于 Web UI 部署。

实验代码采用模块化组织结构, 共 21 个实验模块 (Module 00-20), 每个模块包含独立的 configs/、data/、scripts/ 目录, 通过 shared/ 目录下的公共脚本实现训练、评估、标签生成等核心功能的复用。环境变量通过 setup.env 统一管理, check_env.sh 用于新环境的依赖检查。

3.2 数据集构建

3.2.1 CMExam 牙科子集 (小数据集)

本研究的初始实验 (Module 00-14) 使用 CMExam 牙科子集。训练集 672 题, 验证集 74 题, 测试集 83 题固定不变, 选项类型为五选一 (A/B/C/D/E)。数据格式为 JSONL, 每条记录包含题目文本 (question)、五个选项 (option_A-option_E) 标准答案 (answer)。

数据质量审计方面, 对全部数据进行了逐条审计, 发现并处理以下问题: 训练集第 92 题存在选项 D/E 重复, 已修正 E 为 famotidine; 有 3 题选项数不足 5 个, 已标记但不影响训练; 未发现重复题目或无效答案。数据经溯源审计, 100% 来自 CMExam 原始题库。

83 题测试集中, 每答对/错 1 题产生 ± 1.20 个百分点的准确率变化。这意味着 2-3pp 的差异可能仅由 1-2 题的随机波动导致, 种子方差 (标准差 2-3pp) 对实验结论的可靠性构成挑战。这一局限性在 Module 15 中通过扩展至 991 题测试集得到解决。

3.2.2 全量数据重分割（大数据集）

为获得更高的统计置信度，Module 15 将数据范围扩展至 CMExam 全量 6,591 道单选题（涵盖 7 个临床学科），按难度分层抽样（seed=2026）重新划分：训练集 4,608 题，验证集 991 题，测试集（全量）991 题，测试集（牙科子集）125 题。

全量测试集的 95% 置信区间为 $\pm 2.5\text{pp}$ ，14B 3-seed 极差从旧实验的 4.82pp 降至 0.70pp，验证了大测试集在降低种子方差方面的显著效果。

3.2.3 教师标签生成

本研究采用三种方式生成教师标签，对应不同类型的教师模型。

方式一：API 教师标签。适用于 DeepSeek-V3、豆包、Kimi 等 API 教师。通过调用教师 API 获取每道题的答案，由于 API 仅返回最终选项字母（如 “B”），需人工构造软标签： $p_{\text{correct}} = 1 - \epsilon$, $p_{\text{other}} = \epsilon/4$ ，其中 ϵ (smooth_eps) 为平滑系数，默认取 0.05 或 0.25。

方式二：vLLM 本地 logprobs。适用于可本地部署的大模型（如 Llama-3.3-70B-AWQ）。通过 vLLM 推理引擎直接提取教师在 A/B/C/D/E 五个 token 上的真实 logprobs 概率分布，无需人工平滑。

方式三：本地白盒 logprobs。适用于 Qwen2.5-32B 等可完整加载的本地模型，直接获取全 vocab logit 后提取选项 token 的概率。

3.3 Choice-Head 两阶段蒸馏

Choice-Head 两阶段蒸馏是本文围绕“选择题如何蒸馏”提出的方法设计。与其让学生去拟合整个词表上的分布，不如直接对最终决策所依赖的选项概率进行约束。这样处理后，蒸馏目标与任务形式保持一致，同时也绕开了传统 LLM 蒸馏中最棘手的三类问题：全词

表监督维度过高、API 教师无法暴露内部 logits、白盒蒸馏需要同时加载大教师与学生而带来的显存压力。

3.3.1 Stage 1: Choice-Head KL 蒸馏

Stage 1 的出发点是把蒸馏问题重写为选项分布匹配问题。在五选一任务中，真正决定最终答案的并不是完整词表上的十几万维概率而是 A/B/C/D/E 这五个候选项之间的相对偏好。基于这一点，本文将教师和学生都投影到五维选项空间中进行比较，从而把原本 151,936 维的全词表蒸馏约束收缩为任务相关的五维监督。

具体实现时，对于学生模型的答案位置，提取 A/B/C/D/E 对应 token 的 logit，并经 softmax 归一化得到选项概率分布 $p_S \in R^5$ ：

$$p_S = \text{softmax}(z_S[t_A, t_B, t_C, t_D, t_E])$$

其中 t_A, t_B, t_C, t_D, t_E 分别表示五个选项字母对应的 token ID。若教师来自本地白盒模型，可直接读取其对应的选项分布；若教师来自 API，只需获得选项级概率或可恢复的 logprobs 信息即可。

Stage 1 的训练目标为：

$$L_{\text{stage1}} = \alpha \cdot D_{KL}(p_T \parallel p_S) + (1 - \alpha) \cdot L_{CE}$$

其中 p_T 为教师软标签， $\alpha=0.35$ 为默认蒸馏权重。该阶段通常只训练 1 个 epoch，重点不是让学生立即完全收敛，而是先学习教师对于干扰项与正确项之间的相对判断模式。

3.3.2 Stage 2: GT SFT 精校

Stage 2 继承 Stage 1 训练得到的 LoRA 权重，使用标准答案进行纯监督微调（SFT），目的是纠正 Stage 1 中因教师错误预测导致的偏移：

$$L_{\text{stage2}} = -\log P_{\theta}(y^{\hat{c}} \mid x)$$

Stage 2 通常训练 2–5 个 epoch。通过保留 Stage 1 学到的教师“暗知识”（选项间的相对难度信息），同时用 GT 标签锚定正确答案方向，实现知识迁移与答案校准的平衡。

3.3.3 两阶段策略分析

两阶段策略的核心假设是：Stage 1 的蒸馏让学生获得教师的“认知框架”（哪些选项容易混淆、哪些干扰项有迷惑性），Stage 2 的 SFT 在此基础上修正教师的错误，最终效果优于纯 SFT。

然而，实验发现这一假设仅在特定条件下成立。当学生基线准确率 $\leq 77\%$ (7B) 时，Stage 2 效果为正面 (+2–4pp)，原因在于学生需要 GT 校准来纠正教师的约 14% 错误；当学生基线准确率 $\geq 83\%$ (14B) 时，Stage 2 效果为负面 (-1.6pp 均值)，原因在于学生已足够强，Stage 2 的 GT SFT 反而“过校准”，破坏了 Stage 1 学到的细微概率结构。

这一发现对实际部署有重要指导意义：当学生模型基线足够强时，应仅使用 Stage 1 蒸馏跳过 Stage 2。

3.4 白盒 Logit-KL 蒸馏

作为 Choice-Head 蒸馏的对照方法，本研究在 Module 01 中实现了传统的白盒 Logit-KL 蒸馏。该方法同时加载教师模型（Qwen2.5-32B-Instruct）和学生模型（Qwen2.5-7B-Instruct），直接最小化两者在全 vocab 维度上的 KL 散度：

$$L_{\text{whitebox}} = \alpha T^2 D_{KL}(\sigma(z_T/T) \parallel \sigma(z_S/T)) + (1 - \alpha) L_{CE}$$

其中 $T=2.0$ 为温度参数， $\alpha=0.1$ （含 1 epoch warmup）。该方法的优点是获得完整的 vocab 级别教师信息，但劣势明显：需同时加载 32B + 7B 模型，显存约 90GB；151,936 维 logit 中仅 5 个选项 token 与任务相关，信噪比极低；无法使用 API-only 教师。

3.5 多教师融合策略

3.5.1 静态标签融合 (Module 07)

将多个教师的软标签按测试集准确率加权融合为统一分布：

$$p_{\text{fused}} = \sum_k w_k p_{T_k}, w_k = \frac{acc_k}{\sum_j acc_j}$$

本研究使用 4 个教师 (Doubao, DeepSeek, Qwen-32B, Qwen-14B)，权重分别为 0.285, 0.254, 0.240, 0.222。

3.5.2 多票自一致性过滤 (Module 08)

对每个教师模型进行 $N=9$ 次独立采样 (temperature=0.9)，统计各选项的投票频率作为软标签。同时根据自一致性分数（最高投票比例）对样本进行置信度过滤：自一致性 ≥ 0.78 时全权重参与蒸馏 $0.56 \leq$ 自一致性 < 0.78 时权重减半，自一致性 < 0.56 时排除（回退到 GT 标签）。

3.6 信息几何引导优化

3.6.1 α -散度替代 KL (Module 17)

在 Choice-Head 蒸馏框架中，将 KL 散度替换为通用 α -散度：

$$D_{\alpha}(p_T \parallel p_S) = \frac{4}{1-\alpha^2} \left(1 - \sum_i p_{T_i}^{(1+\alpha)/2} p_{S_i}^{(1-\alpha)/2} \right)$$

对 $\alpha=1.0$ （前向 KL）、 $\alpha=0.5$ （混合）、 $\alpha=0.0$ （Hellinger）、 $\alpha=-1.0$ （逆向 KL）四种配置进行了控制实验。

3.6.2 Fisher-Rao 距离教师质量分析 (Module 18)

利用 fisher_rao_analysis.py 对所有教师的软标签进行几何特征分析计算 Fisher-Rao 到 GT 的距离、Shannon 熵、流形体积密度、边界测地距离和教师间 Fisher-Rao 距离矩阵。

3.6.3 边界距离置信度过滤 (Module 19)

基于教师答错样本的边界距离是答对样本 2 倍的发现，设计了基于边界距离的数据过滤策略。Hard 过滤设阈值 d_b^i ，仅保留 $d_b < d_b^i$ 的样本使用教师标签蒸馏，其余样本回退到 GT 标签。Soft 加权用 sigmoid 函数对蒸馏权重进行连续调整：

$$w_i = \sigma \left(-\frac{d_b - d_b^i}{0.01} \right)$$

3.6.4 样本自适应 α -散度 (Module 20)

基于 KL 种子敏感性最大、Hellinger 更稳健的发现，设计了根据样本边界距离动态选择 α 值的策略：

$$\alpha_i = \sigma \left(\frac{d_{\text{boundary}} - \tau}{\gamma} \right) (\alpha_{\text{high}} - \alpha_{\text{low}}) + \alpha_{\text{low}}$$

教师自信的样本（边界距离小）使用 α_{low} （如 KL），教师犹豫的样本（边界距离大）使用 α_{high} （如 Hellinger）。

3.7 LoRA 微调配置

除特别说明外，所有实验统一使用以下 LoRA 参数：LoRA Rank (r) = 16, LoRA Alpha (α_{lora}) = 16, 目标模块为 q_{proj} 和 v_{proj} , Dropout = 0.0, 数据类型为 bfloat16。可训练参数方面，7B 模型约 13M (0.17%)，14B 模型约 16M (0.11%)。

需要说明的是，QLoRA 证明了 4-bit 量化基座模型与 LoRA 适配器结合后，可以把微调显存进一步压缩到更低水平，是参数高效训练的重要延伸路线。本文最终仍以标准 LoRA 为主而未在主实验中采用 QLoRA，主要原因在于本研究更关注蒸馏标签质量与教师形态差异，对训练稳定性和跨模块可比性的要求高于极限省显存需求；在 H100 环境下，LoRA 已能满足 7B 与 14B 学生的训练预算。

3.8 系统部署架构

本研究实现了两个面向用户的 Web 应用。

模型推理服务（serve_model_app.py，端口 7860）基于 Gradio 构建，支持用户输入自然语言问题并获取模型回答。后端支持 vLLM 和 Transformers 两种推理引擎，前者用于高吞吐场景，后者用于兼容性回退。系统支持 LoRA 适配器热切换，用户可在不重启服务的情况下切换不同实验训练得到的模型。

人类测验界面（quiz_app.py，端口 7870）从测试集 JSONL 文件中随机抽取选择题，用户作答后即时显示对错和正确答案，用于人机性能对比和模型效果演示。

第四章 实验结果与分析

4.1 实验组织与报告口径

为确保横向可比，本章统一使用以下口径：小规模口径为 83 题牙科测试集（Modules 00-14），大规模口径为 991 题全量测试集（Modules 15-20 另含牙科 125 子集）。结果类型方面，峰值（best seed）与均值（multi-seed mean）并列报告。增益定义为与对应学生零样本或 GT SFT 基线的准确率差值（pp）。

4.2 基线与教师能力上界

4.2.1 学生基线 (Module 00)

Qwen2.5-7B-Instruct 经纯 GT SFT 后在 83 题牙科测试集上达到 77.11% 的准确率。该结果定义了 7B 蒸馏实验的第一比较基准线。Qwen2.5-14B-Instruct 的零样本准确率为 83.13%，定义了 14B 蒸馏实验的基准。

表 4-1 教师模型能力谱系与训练集不一致率比较

教师模型	形态	83题准确率	训练集不一致率
豆包 (Doubao)	API 推理模型	98.80% (82/83)	0.33% (2/604)
DeepSeek-V3	API (MoE)	87.95% (73/83)	14.14% (95/672)
Qwen2.5-32B-Instruct	本地白盒/API	83.13% (69/83)	约 5%
Qwen2.5-14B-Instruct			

本地/API

77.11% (64/83)

20.24% (136/672)

Kimi (moonshot-v1-32k)

API

61.45% (51/83)

0%

由于 Llama-3.3-70B 的异构教师实验使用的是 Module 15 的 991 题全量重分割设定，而非这里的 83 题牙科旧设定，因此未直接并入表 4-1。其已核验指标为：991 题教师准确率 72.45%，训练集不一致率 27.21%，对应的蒸馏结果见表 4-4、表 4-5 与 4.9 节。

答辩要点在于教师“越强越好”并不成立，不一致率决定了可迁移暗知识的有效区间。

4.3 白盒蒸馏 (Module 01)

白盒 Logit-KL (32B → 7B) 的结果为测试准确率 80.72%，相对基线提升 +3.61pp，训练资源代价约 90GB 显存（教师与学生并行）
白盒方法有效但工程性差，为后续黑盒 Choice-Head 奠定对照基线

4.4 单教师黑盒 Choice-Head (Modules 02-06)

表 4-2 单教师黑盒 Choice-Head 蒸馏总体结果
模块
教师
教师准确率
学生峰值
学生稳定值
vs 基线
02
DeepSeek-V3
87.95%
81.93%
79.52%
+4.82pp
03
豆包
98.80%
80.72%

79.52%
+3.61pp
04
Kimi
61.45%
77.11%
约 76%
 ± 0.00
05
Qwen2.5-14B
77.11%
75.90%
约 75.5%
-1.21pp
16*
Llama-3.3-70B-AWQ
72.45%*
87.59%*
87.25%*
+3.70pp*

注：带 * 的 Module 16 结果基于 991 题全量测试集与 14B 学生，不属于上表 83 题牙科 7B 单教师设定，因此作为跨架构参考行展示。

4.4.2 DeepSeek-V3 详细结果 (Module 02)

5-seed结果显示明显高方差：seed=11时准确率为 81.93%
seed=7 和 seed=99 时为 77.11%，seed=55 时为 75.90%，seed=42

时为 72.29%，均值 $\pm$ std 为 $76.87\% \pm 3.09$ 。峰值可高，但小测试集下必须结合均值看稳定性。

4.4.3 豆包详细结果 (Module 03)

5-seed 结果：seed=42 和 seed=55 时准确率为 79.52%，seed=11 时为 78.31%，seed=7 和 seed=99 时为 74.70%，均值 $\pm$ std 为 $77.35\% \pm 2.21$ 。解释为教师过强且与 GT 过一致（0.33% 不一致率），蒸馏信号退化为伪标签 SFT。

4.5 多教师融合与一致性过滤 (Modules 07-08)

4.5.1 静态融合 (Module 07)

最优配置准确率为 79.52%，未超过 DeepSee 单教师峰值 81.93%。

4.5.2 多票一致性过滤 (Module 08)

默认过滤、无过滤、严格过滤三种配置均达到 79.52%。过滤策略未带来收益，核心原因是教师自身一致性已高，过滤不改变数据分布。

4.6 集成与 CoT 蒸馏 (Modules 11-12)

4.6.1 多 seed 集成 (Module 11)

7-seed 集成达到 79.52%，等于最佳单 seed，未形成超越。

4.6.2 CoT 蒸馏失败 (Module 12)

最终测试准确率为 73.49%，相比基线下降 -3.62pp。失败机制包括序列变长导致训练信号稀释、训练目标与评估目标不一致、7B 容量不足以稳健吸收推理链监督。

4.7 学生容量升级 (Modules 13-14)

4.7.1 Qwen2.5-14B (Module 13)

Stage 1 (仅蒸馏)：峰值 84.34%，均值 82.33%。Stage 2 (追加 GT SFT)：均值 80.72%，相比 Stage 1 下降 -1.61pp。关键结论为强学生出现二阶段回退，证明“二阶段并非普适最优”。

4.7.2 Qwen3-14B (Module 14)

最佳结果为 81.93%，均值为 80.72%。在本任务的直答评估模式下 Qwen2.5-14B 仍优于 Qwen3-14B Qwen3-14B 零样本基线为 79.52%，低于 Qwen2.5-14B 的 83.13%，这表明 Qwen3 的架构为推理链优化，在直答场景下表现相对较弱。

4.8 全量重分割验证 (Module 15)

本节是本研究结论可信度的关键支点。测试规模由 83 提升到 991，显著降低统计噪声。

表 4-3 全量测试集与牙科子集零样本基线结果
模型
全量 991
牙科 125
Qwen2.5-7B

76.49%
68.80%
Qwen2.5-14B
83.55%
74.40%
DeepSeek-V3 教师
87.18%
79.20%
Llama-70B-AWQ 教师
72.45%
—

注：Llama-70B 在 125 题牙科子集上的教师单独评测值未在原始实验产物中保存，因此此处仅列出已核验的 991 题全量教师分数。

表 4-4 全量数据重分割下的蒸馏结果比较
模型
配置
全量均值
全量最佳
牙科均值
7B

Stage 1

85.60%

86.28%

73.60%

7B

Stage 2

85.20%

85.77%

73.33%

14B

Stage 1 only

88.67%

89.10%

79.20%

14B

Llama-70B 教师 (Module 16)

87.25%

87.59%

80.00%

4.8.3 核心发现

三项关键发现如下。第一，学生超越教师，14B 均值 88.67% 超过 87.18% (+1.49pp)，最佳 89.10% 超过教师 +1.92pp。第二，种子稳定性显著增强，14B 极差仅 0.70pp（对比旧小集的 4.82pp）。第三，7B 在大数据下也观察到 Stage 2 轻微负效应 (-0.40pp)。作为补充对照，Llama-70B 异构教师虽然自身仅有 72.45%，但蒸馏后

14B 学生仍达到 87.25% 均值，并在牙科子集上取得 80.00%，说明真实 logprobs 的结构信息足以支撑竞争性结果。

4.9 跨架构蒸馏 (Module 16)

Llama-70B-AWQ (真实 logprobs) $\rightarrow$ Qwen2.5-14B 的实验中，教师准确率 (991题) 为 72.45%，学生全量均值为 87.25%，学生牙科均值为 80.00%。结论为真实概率分布的结构信息（而非教师最终准确率）对蒸馏具有高价值。即使教师准确率仅为 72.45%（低于 DeepSeek 的 87.18%），但真实 logprobs 提供的选项混淆模式信息使蒸馏效果与 DeepSeek 教师竞争性持平。

4.10 信息几何实验 (Modules 17-20)

4.10.1 α -散度 (Module 17)

在统一超参下， $\alpha=0.5$ 与 Hellinger($\alpha=0$) 均值优于 KL 约 1.81pp，提示弱软标签场景下非 KL 更稳健。

4.10.2 Fisher-Rao 分析 (Module 18)

关键结论：smooth_eps 标签熵与峰值几乎恒定，暗知识有限；真实 logprobs 在概率流形上提供更细粒度混淆结构。具体而言，真实 logprobs 标签的体积密度比 smooth_eps 标签高约 2500 倍，证实了两类标签在几何性质上的本质差异。

4.10.3 边界距离过滤 (Module 19)

最优 hard 阈值配置带来 +0.86pp 增益，说明“高置信教师样本优先蒸馏”有效。

4.10.4 自适应 α (Module 20)

全部策略均低于固定 KL 基线 (-3.98pp 至 -5.80pp)，个别配置出现训练崩溃，说明当前映射策略不稳定，需进一步优化。

4.11 错误分析

在代表性 80.72% 运行中，错误主要集中于以下类型：阈值/范围题（如厚度、比例、边界值）占 25.0% 解剖近邻结构混淆占 25.0%，影像/体征混淆占 12.5%，多证据联合判定占 12.5%，否定逻辑题占 6.25% 疾病术语辨识占 6.25% 生化通路定位占 6.25%，机制语义辨析占 6.25%。

这表明模型已具备医学知识框架，但在高精度知识边界题与复杂逻辑题仍需改进。按知识领域划分：疾病治疗准确率为 86.67%，公共卫生/伦理为 83.33%，医学基础为 80.00%，诊断/鉴别为 76.47%。

表 4-5 全部实验的代表性结果汇总
排名

方法

学生模型

教师

准确率

vs 基线

1

14B Stage1 (Module 15, seed=8)

Qwen2.5-14B

DeepSeek-V3

89.10%

+5.55pp

2

14B Stage1 均值 (Module 15)

Qwen2.5-14B

DeepSeek-V3

88.67%

+5.12pp

3

14B Llama-70B 均值 (Module 16)

Qwen2.5-14B

Llama-70B-AWQ

87.25%

+3.70pp

4

7B Stage1 (Module 15, seed=11)

Qwen2.5-7B

DeepSeek-V3

86.28%

+9.79pp

5

7B Stage1 均值 (Module 15)

Qwen2.5-7B

DeepSeek-V3

85.60%

+9.11pp

—

DeepSeek-V3 教师

—

—

87.18%

—

—

Llama-70B 教师

—

—

72.45%

—

—

14B 零样本

—

—

83.55%

—
—
7B 零样本
—
—
76.49%
—

第五章 讨论与结论

5.1 研究贡献总结

相较于将本文理解为一组彼此独立的实验结果，更准确的表述是：本研究围绕牙科选择题场景，构建了一条从问题提出、方法设计、实证验证到理论解释逐步闭合的研究路径。第五章因此不再重复第四章的结果罗列，而是从整体研究价值的角度，对本文的主要贡献结论边界与后续发展方向进行归纳。

综合全文，可以将本文的研究贡献概括为以下五个方面。

第一，本文提出了面向标准化多选任务的 Choice-Head 两阶段蒸馏方案，把蒸馏监督从高维全词表压缩到选项级概率空间。这样既降低了训练成本，也使 API 教师与本地教师能够被纳入同一实验框架进行比较。实际结果显示，该方案相较纯 SFT 基线在 7B 与 14B 学生上都带来了稳定收益。这一贡献的意义在于，它证明了选择题任务可以围绕“决策头”而不是“全词表”来重新定义蒸馏目标。

第二，本文发现教师质量与蒸馏收益之间并不是线性关系。通过多种教师的对照实验可以看到，真正决定蒸馏效果的不是教师分数本身，而是教师输出中是否保留了足够丰富、又不过度失真的判别结构。这使“教师-GT 不一致率”成为比“教师绝对准确率”更有解释力的观察指标。换言之，本文把教师选择问题从“谁分数最高”推进到了“谁提供的可迁移信息最有价值”。

第三，本文揭示了两阶段训练并非对所有学生都同样有利。对于较弱学生，Stage 2 的 GT 校准能够修正教师误差；但对更强的 14B 学生，继续执行 Stage 2 反而会破坏 Stage 1 中学到的细粒度概率结构。这一结果说明，蒸馏后的再校准并不天然安全，训练阶段的设计需要与学生能力匹配。它也提示，所谓“更完整的训练流程”并不一定意味着“更优的最终性能”。

第四，本文验证了任务头蒸馏对跨架构教师具有一定适应性。即使教师与学生不属于同一模型家族，选项级概率分布仍然可以作为稳定知识载体。Llama-3.3-70B 到 Qwen-14B 的结果说明，模型结构差异并不会天然阻断有效蒸馏。这使本文的方法不局限于单一模型生态而具备更现实的可迁移性。

第五，本文将信息几何视角引入教师标签分析，为实验观察提供了额外解释框架。通过 Fisher-Rao 距离与 α -散度分析，本文进一步说明了为什么某些教师虽然分数更高，却未必产生更好的蒸馏结果，以及为什么人工平滑标签难以替代真实 logprobs。这个部分的价值在于，它使全文不只停留在经验对比层面，而开始具备对蒸馏现象进行结构化解释的理论基础。

5.2 研究局限性

在确认本文贡献的同时，也必须明确其成立条件和外推边界。以下局限性并不否定本文结论，而是用于说明这些结论目前在哪些范围内是可信的、在哪些范围内仍需要更强证据支持。首先，数据规模与数据覆盖面仍是影响结论稳定性的主要因素。早期实验依赖 83 题牙科测试集，容易受到单题波动和随机种子差异的影响；虽然 Module 15 已将测试规模扩展到 991 题并显著改善统计可靠性，但该评测仍主要建立在考试题分布上，牙科子集也只有 125 题，尚不足以完全代表真实临床咨询中的问题复杂度、表述多样性和知识更新频率。因此，本文结论更适用于“标准化牙科考试型知识问答”场景，而不宜直接外推到开放环境下的通用医疗问答。

其次，教师模型谱系仍然偏窄，这限制了对“教师质量与蒸馏收益关系”这一结论的进一步细化。本文虽然覆盖了强教师、弱教师、API 教师与异构教师等多种情形，但总量仍只有 5 个主要教师，且在 85%–95% 准确率区间缺少更密集的中间样本。换言之，本文已经验证了倒 U 型关系的存在，却尚未给出该曲线在不同任务规模、不同学生容量和不同标签质量条件下的精确形状。类似豆包这类极高准确率教师的表现，也可能受到具体任务分布和接口返回形式的共同影响，因此当前结果更适合被理解为“强证据的经验发现”，而非已完成普适证明的理论定律。

第三，本文方法本身仍依赖任务结构假设。Choice-Head 蒸馏的优势来自于对五选一决策空间的压缩建模，但这也意味着方法天然更适合标准化多选任务。对于开放式问答、病例推理、长文本解释生成等任务，教师需要传递的信息不再局限于少量候选项之间的相对权重，当前框架无法直接复用。此外，本文在训练配置上仍保持了较强的工程简化，例如固定 LoRA rank=16、未系统搜索 rank $\in\{4,8,16,32,64\}$ 的影响、未采用课程学习或难度感知采样，这些选择有助于控制变量，却也限制了方法上界的进一步探索。

最后，评估维度仍偏重结果正确性，而对回答质量的细粒度考察不足。本文主要使用精确匹配准确率作为统一指标，这对于标准化考试题是合理的，但仍难以全面反映模型在解释性、稳健性和临床可用性方面的表现。当前评估主要基于 do_sample=false 的确定性推理，尚未系统分析采样策略变化对输出稳定性的影响，也未引入人工盲评、错误严重程度分级或推理过程质量评价。因此，本文证明的是学生模型在“标准答案对齐”上的有效性，而非其在真实医疗交互环境中已经具备充分可靠的辅助能力。

5.3 未来工作方向

基于上述局限性，未来工作不应只是机械地增加更多实验，而应围绕“如何让现有结论更可靠、让方法边界更清晰、让系统更接近真实应用”三个目标展开。整体上，可以沿着“先提升证据强度，再扩展任务边界，最后推动场景落地”的顺序推进。

短期内，最直接的工作仍是增强现有实验结论的可靠性与可复现性。一方面，可以进一步扩充训练与评测数据，引入更多高质量牙科题目，并继续扩大多种子实验规模，以区分真实增益和随机波动。另一方面，可以系统搜索 LoRA rank、蒸馏权重、阶段训练时长等关键超参数，建立更完整的性能响应面，而不是仅依赖少数经验配置。对于本文已经观察到的 Stage 2 负效应、教师倒 U 型关系以及 α -散度替代 KL 的潜力，也都值得在更严格的控制实验中重复验证，从而把当前的经验结论固化为更稳健的实验事实。

中期来看，更值得投入的是围绕“教师信号质量”继续做方法演进。一个自然方向是构建教师路由或样本级教师选择机制，使不同题型、不同难度的问题能够自动匹配最有价值的教师分布，而不再依赖单一固定教师。另一个方向是把检索增强、动态 α 调度、边界距离过滤和错误模式感知训练整合起来，形成更加自适应的蒸馏流程。这样的方法不只是提高平均准确率，更重要的是让学生模型在薄弱题型、边界样本和高混淆样本上获得更稳定的改进。

长期来看，本文框架仍需跨越三个更大的扩展方向。第一，是从牙科单一科目走向多学科甚至跨考试体系的泛化验证，检验 Choice-Head 蒸馏究竟是牙科场景特例，还是对更广泛标准化评测任务都成立。第二，是从纯文本选择题走向更复杂的医疗任务，例如开放式病例分析、图文联合题目和影像诊断相关场景，这要求蒸馏目标从简单选项分布扩展到多模态或更长程的推理表征。第三，是走向真正可部署的终端系统，包括结合量化、端侧推理、检索模块和人机交互设计，把实验中的学生模型逐步转化为可服务真实教学、科普或临床辅助流程的应用原型。只有在这些方向上继续推进，本文提出的 Choice-Head 框架才可能从一个有效的研究方案，进一步发展为具备长期应用价值的方法体系。

5.4 结论

综合全文，本文所回答的并不只是“如何把一个更小的模型训练得更准”，而是医疗大语言模型在资源受限条件下能否通过合理的知识迁移获得可部署能力。以牙科选择题自动答题为切入点，本文的核心结论是：当蒸馏目标能够与任务决策结构对齐时，轻量学生模型并不只能被动追赶教师，而有机会在更合适的训练配置下获得超

过教师的任务表现。Choice-Head 框架之所以有效，关键并不是简单复制教师答案，而是让学生学习教师在候选选项之间形成的相对偏好与混淆关系。

据此，本文对“优质教师信号”的判断标准也作了修正。真正关键的并非教师在测试集上的绝对分数，而是其输出分布是否还保留了足够细的可迁移结构。以本文实验为例，

DeepSeek-V3 虽然总体准确率低于豆包，但在候选选项之间呈现出更可学习的层次差异，因此对学生训练更有帮助；反之，如果教师输出已经近似 one-hot，蒸馏过程就会越来越接近普通监督训练，软标签本身提供的额外信息也会明显收缩。

从结果上看，本文最具代表性的实证发现是在 45 倍参数压缩条件下，14B 学生模型在 991 题全量测试集上达到 89.10%，超过 87.18% 的 DeepSeek-V3 教师。这一结果说明面向选择题的任务头蒸馏不仅能够降低硬件成本，也具备形成性能增益的潜力。对医疗领域以及其他标准化评测任务而言，这意味着高质量知识迁移并不一定依赖完整白盒访问，围绕任务结构重新设计蒸馏目标同样可以产生可观收益。

因此，本文的最终价值并不只在于给出一个在牙科数据上表现良好的实验配置，而在于说明了一种更具普遍性的研究思路：当任务形式足够明确时，蒸馏目标可以从通用大模型训练范式中抽离出来，重新围绕任务本身进行定义。Choice-Head 框架能否进一步推广到更广泛的医疗评测与交互场景，仍需后续研究继续验证；但至少在本文所覆盖的实验边界内，它已经展示出明确的方法有效性、解释价值与应用潜力。

参考文献

- [1] Vaswani, A., et(2017). Attention Is All You Need. NeurIPS 2017.
- [2] OpenAI. (2023). GPT-4 Technical Report. arXiv:2303.08774.
- [3] Meta. (2024). The Llama 3 Herd of Models. arXiv:2407.21783.
- [4] Qwen Team. (2024). Qwen2.5 Technical Report. arXiv:2412.15115.

- [5] Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the Knowledge in a Neural Network. NIPS Workshop.
- [6] GLM Team. (2024). ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools. arXiv:2406.12793.
- [7] Bao, Z., et al. (2023). DISC-MedLLM: Bridging General Large Language Models and Real-World Medical Consultation. arXiv:2308.14346.
- [8] Zhang, H., et al. (2023). HuatuoGPT, Towards Taming Language Model to Be a Doctor. Findings of the Association for Computational Linguistics: EMNLP 2023.
- [9] Wang, X., et al. (2025). Huatuo-26M, a Large-scale Chinese Medical QA Dataset. Findings of the Association for Computational Linguistics: NAACL 2025.
- [10] Chong, D., et al. (2023). Benchmarking Large Language Models on CMExam - A Comprehensive Chinese Medical Exam Dataset. NeurIPS 2023.
- [11] Jin, D., et al. (2021). What Disease Does This Patient Have? A Large-Scale Open Domain Question Answering Dataset from Medical Exams. Applied Sciences, 11(14), 6421.
- [12] Jin, Q., & Dhingra, B. (2019). PubMedQA: A Dataset for Biomedical Research Question Answering. EMNLP-IJCNLP 2019.
- [13] Romero, A., et al. (2015). FitNets: Hints for Thin Deep Nets. ICLR 2015.
- [14] Zagoruyko, S., & Komodakis, N. (2017). Paying More Attention to Attention: ICLR 2017.

- [15] Snell, C., et al. (2022). Scaling Laws for Knowledge Distillation.
[Bibliographic record pending verification; recommended for deletion or replacement before final submission].
- [16] West, P., et al. (2022). Symbolic Knowledge Distillation: from General Language Models to Commonsense Models. NAACL 2022.
- [17] Hu, E. J., et al. (2022). LoRA: Low-Rank Adaptation of Large Language Models. ICLR 2022.
- [18] DeepSeek AI. (2024). DeepSeek-V3 Technical Report. arXiv:2412.19437.
- [19] Amari, S. (2016). Information Geometry and Its Applications. Springer.
- [20] Rao, C. R. (1945). Information and the Accuracy Attainable in the Estimation of Statistical Parameters. Bulletin of the Calcutta Mathematical Society, 37, 81-91.
- [21] Yang, Z., et al. (2020). TextBrewer: An Open-Source Knowledge Distillation Toolkit for Natural Language Processing. ACL 2020 System Demonstrations.
- [22] Sanh, V., et al. (2019). DistilBERT, a Distilled Version of BERT. NeurIPS 2019 Workshop.
- [23] Lin, J., et al. (2024). AWQ: Activation-Aware Weight Quantization for LLM Compression. MLSys 2024.
- [24] Dettmers, T., et al. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. NeurIPS 2023.
- [25] Su, J., et al. (2021). RoFormer: Enhanced Transformer with Rotary Position Embedding. arXiv:2104.09864.

附录

附录 A：可复现参数索引

表 A-1 实验 00 的关键训练参数

参数

值

model

Qwen2.5-7B-Instruct

learning_rate

2e-4

num_epochs

5

batch_size

4

rank

16

lora_alpha

32

seed

42

预期结果

77.11% (64/83)

实验 02: *DeepSeek-V3* $\rightarrow$ 7B 两阶段

表 A-2 实验 02 的两阶段训练参数
参数

Stage 1

Stage 2

learning_rate

1.2e-4

1.2e-4

num_epochs

1

2

alpha

0.35

0.0

batch_size $\times$ grad_accum

$2 \times 4 = 8$

$2 \times 4 = 8$

seeds

{11, 42, 7, 99, 55}

同

预期峰值

81.93% (seed=11)

预期稳定值

79.52%

实验 13：14B 学生 + DeepSeek 教师（最佳配置）

表 A-3 实验 13 的关键训练参数

参数

Stage 1

Stage 2（不推荐）

learning_rate

1e-4

1e-4

num_epochs

1

5

alpha

0.35

0.0

seeds

{42, 11, 8}

同

预期峰值

84.34% (seed=11, 83题)

预期均值

82.33%

80.72%

表 A-4 实验 15 的最终配置与预期结果

参数

7B（两阶段）

14B（Stage1 only）

student

Qwen2.5-7B-Instruct

Qwen2.5-14B-Instruct

teacher

DeepSeek-V3 API

同

train_data

4,608 题（全量 7 学科）

同

test_data

991 题（全量） + 125 题（牙科）

同

learning_rate

1.2e-4

1e-4

num_epochs

S1: 1, S2: 2

1

alpha

S1: 0.35, S2: 0.0

0.35

seeds

11, 42, 7

11, 42, 8

预期最佳

86.28%（seed=11, 全量）

89.10%（seed=8, 全量）

预期均值

85.60%（全量）

88.67%（全量）

表 B-1 关键代码文件与功能说明

文件路径

功能描述

shared/train_choice_head_distill.py

Choice-Head 两阶段蒸馏核心训练脚本

shared/evaluate_model.py

模型评估脚本，支持多种子和双测试集

shared/generate_teacher_labels_api.py

API 教师标签生成

shared/generate_teacher_labels_vllm.py

vLLM 本地 logprobs 标签生成

shared/fisher_rao_analysis.py
Fisher-Rao 距离与信息几何分析

shared/train_alpha_distill.py
 α -散度蒸馏实验

shared/train_boundary_filter_distill.py
边界距离置信度过滤实验

shared/serve_model_app.py
Gradio 模型推理 Web UI (端口 7860)

shared/quiz_app.py
人类测验界面 (端口 7870)

表 C-1 实验硬件资源与显存需求汇总

实验阶段
GPU 型号
显存需求
备注
7B LoRA 训练
H100 NVL 95GB

~22GB

单卡

14B LoRA 训练

H100 NVL 95GB

~35GB

单卡

32B+7B 白盒蒸馏

H100 NVL 95GB

~90GB

双模型并行

Llama-70B-AWQ 推理

H100 NVL 95GB

~38GB

vLLM

最终推理服务

H100 NVL 95GB

~15GB

INT4 量化 14B

致谢

在研究生学习期间，我得到了许多人的帮助和支持，在此表示衷心的感谢。

首先，感谢我的导师熊体超博士（Dr. Richard Tai-Chiu Hsung）。从论文选题到研究方案设计，从实验实施到论文撰写，导师始终给予我悉心的指导和耐心的帮助。导师严谨的治学态度、渊博的专业知识和敏锐的学术洞察力深深影响了我，为我的研究工作指明了方向。

感谢香港珠海学院资讯科学学系的所有老师，在我硕士学习期间传授了丰富的专业知识，为我的研究打下了坚实的理论基础。

感谢实验室的同学们，在学术讨论中给予我宝贵的建议，在日常生活中给予我温暖的陪伴。特别感谢在知识蒸馏实验过程中给予我帮助的同学，你们的讨论激发了我的研究灵感。

感谢我的家人对我的理解、支持和鼓励。正是由于你们的无私付出，我才能专注于学业，顺利完成研究工作。

最后，感谢所有参与本论文评审和答辩的专家老师们，感谢你们提出的宝贵意见和建议。

陈天元 香港珠海学院 2026 年 5 月