



基于知识蒸馏的牙科选择题自动答题系统

Knowledge Distillation for Dental MCQ Answering

NVIDIA H100 NVL 95GB | CMExam 牙科医师考试选择题

核心结果： 89.10% （14B 学生） > 87.18% （DeepSeek-V3 教师）

专业：应用人工智能

导师：熊体超博士

学号：256360231

答辩人：陈天元

2026 年 5 月

汇报提纲

1. 研究背景与核心问题
2. 数据、目标与实验范围
3. Choice-Head 蒸馏方法
4. 实验体系与设置
5. 核心结果：学生超过教师
6. 关键发现与解释
7. 应用价值、局限与未来工作
8. 结论

核心问题：能否把大模型的牙科答题能力迁移到 7B/14B 学生模型，同时兼顾准确率和部署成本？

研究动机

需要的是低成本、可部署的牙科答题能力

大模型效果好，但推理和部署代价高

传统全词表蒸馏对五选一任务有明显冗余

因此本文重写蒸馏目标，而不是继续堆大模型

数据范围

6,591 题

全量 CMExam 单选题，含牙科子集

实验规模

21 组

覆盖 00-20 模块的系统性实验

学生模型

7B / 14B

Qwen2.5 系列 LoRA 微调

部署约束

45× 压缩

从 671B 教师迁移到 14B 学生

评测设置

小规模：672/74/83 牙科固定划分

大规模：4608/991/991 全量重分割 + 125 题牙科子集

教师覆盖 DeepSeek-V3、Doubao、Llama-70B、Qwen2.5-32B

硬件：NVIDIA H100 NVL 95GB，BF16 混合精度训练

模型参数规模

学生：Qwen2.5-7B / 14B

本地教师：Qwen2.5-32B、Llama-3.3-70B

主要 API 教师：DeepSeek-V3（671B 总参数 / 37B 激活）

Doubao、Kimi 为闭源模型，参数规模未公开

03 核心方法：Choice-Head 两阶段蒸馏

传统全词表蒸馏

151,936 维 logits
代价高
黑盒教师难支持

Choice-Head 蒸馏

只看 A/B/C/D/E
监督降到 5 维
兼容 API 教师

Stage 1

Choice-Head KL + CE
先学教师偏好
1 epoch

Stage 2

GT SFT 精校
再用标准答案校准
2–5 epochs

方法直觉

Stage 1 : Choice-Head KL 蒸馏

只蒸馏五个选项间的相对偏好
损失： $\alpha \cdot \text{KL}(p_T // p_S) + (1-\alpha) \cdot \text{CE}$
显存更低，也能用 API-only 教师

Stage 2 : GT SFT 精校

继承 Stage 1 的 LoRA 权重
用 GT 校正教师误差
对 7B 更稳，对 14B 不一定继续增益

A. 基线建立

GT SFT
7B : 77.11%
先定起点

B. 单教师蒸馏

白盒 Logit-KL
黑盒 Choice-Head
比较监督形式

C. 多教师优化

静态融合
一致性过滤
多数票集成

D. 范式拓展

CoT
 α - 散度
边界过滤

E. 容量升级

14B 学生
跨架构
全量重分割

实验设计特点

从单教师到多教师、从 7B 到 14B 逐层推进
同时保留正例、负例和失败实验
所有模块都保留统一脚本，保证可复现

关键可比性控制

模块之间尽量复用同一学生架构与超参
用多 seed 和大测试集缓解 83 题波动
先给经验结果，再做理论解释

DeepSeek-V3 教师

87.18%

991 题全量测试集准确率

14B 学生最佳

89.10%

Module 15 , seed 8

14B 三种子均值

88.67%

同样超过教师表现

参数压缩比

45×

671B 教师到 14B 学生

最重要的结论

学生不只是接近教师，而是可以超过教师
关键不在流程更复杂，而在蒸馏目标更贴近任务结构

991 题验证后，这个结论更稳健

代表性结果串联

7B GT SFT 基线：77.11%

7B Choice-Head 蒸馏最佳：81.93%

14B DeepSeek 蒸馏最佳：84.34%（83 题牙科）

14B 全量重分割最佳：89.10%（991 题）

06 结果细化：什么条件下蒸馏有效？

白盒 vs 黑盒

白盒 Logit-KL : 80.72%
黑盒 Choice-Head : 81.93%
任务对齐比全词表更重要

Stage 2 的边界

7B 通常受益
14B 均值下降约 1.6pp
强学生可能被过校准

跨架构可行性

Llama-70B 教师: 72.45%
14B 学生仍达 87.25%
教师价值不只看准确率

结论不是“越复杂越好”，而是“监督信号要和任务决策结构匹配”。

本文的价值不只是一组更高分数，更在于给出了可解释的设计原则。

弱教师

Kimi : 62.65%
分歧高但信号质量不足
学生最终与基线持平

较优情形

较高准确率 + 适度 teacher-GT 分歧
保留结构信息，又不过分偏离真值
更容易带来蒸馏增益

过强教师

接近 one-hot
暗知识不足
给不出有效混淆结构

教师质量与蒸馏收益呈倒 U 型，关键在于是否保留了可迁移的不确定性结构。

08 关键发现二：真实 logprobs 更有价值

为什么人工平滑标签不够？

人工平滑只是加固定噪声
看不到最容易混淆的错误项和边界距离
因此只能提供有限的软监督增益

信息几何分析给出的证据

Fisher-Rao 与 α -散度都指向同一结论
真实 logprobs 更接近连续概率流形
体积密度约为人工平滑标签的 2500 倍

决定蒸馏效果的，不只是教师有没有答对，更在于它有没有保留高价值的连续结构信息。

从论文到系统

仓库已提供统一训练、评估和 Web/Quiz 入口
7B/14B 学生模型可完成部署演示
更适合教学演示、考试训练等轻量场景
方法也能迁移到其他标准化多选任务

应用意义

重点不是把大模型原样搬到端侧
而是把“能答题”做成“能低成本交付”
为医疗大模型轻量化提供可复现范式

当前局限

任务仍以标准化选择题为主，尚未覆盖开放问答与长文本推理
教师谱系还不够密集，倒 U 型仍需更细验证
评估以准确率为主，缺少人工和专家反馈
系统目前更多面向研究验证，而非直接临床部署

未来工作

扩大数据与多种子验证，提高统计可信度
研究教师路由、自适应 α - 散度和动态样本选择
从选择题扩展到开放问答、多模态和真实交互
继续推进端侧部署与真实反馈闭环

结论与答辩总结

本文说明：当蒸馏目标和任务决策结构对齐时，小模型不仅更容易部署，也有机会超过教师。

感谢各位老师聆听，恳请批评指正。