



基于知识蒸馏的牙科选择题自动答题系统

Knowledge Distillation for Dental MCQ Answering

NVIDIA H100 NVL 95GB | CMExam 牙科医师考试选择题

核心结果：89.10%（14B 学生） > 87.18%（DeepSeek-V3 教师）

专业：应用人工智能

导师：熊体超博士

学号：256360231

答辩人：陈天元

2026 年 5 月

汇报提纲

1. 研究背景与问题定义
2. 研究目标、数据与实验范围
3. 核心方法：Choice-Head 两阶段蒸馏
4. 实验体系与设置
5. 核心结果：学生超过教师
6. 关键发现与理论解释
7. 应用价值、局限与未来工作
8. 结论与答辩总结

核心问题：能否通过知识蒸馏，将大型教师模型的答题能力迁移到轻量级学生模型（7B~14B），在保持可部署性的同时最大化准确率？

研究动机

牙科知识服务需要即时、低门槛、可解释的辅助能力

商业级教师模型准确率高，但显存、算力和调用成本高

传统全词表蒸馏对五选一任务存在明显冗余

研究目标不是做更大模型，而是把高性能能力做成可部署系统

数据范围

6,591 题

全量 CMExam 单选题，含牙科子集

实验规模

21 组

覆盖 00-20 模块的系统性实验

学生模型

7B / 14B

Qwen2.5 系列 LoRA 微调

部署约束

45× 压缩

从 671B 教师迁移到 14B 学生

评测设置

小规模实验：672/74/83 (train/val/test) 牙科固定划分

大规模验证：4608/991/991 全量重分割 + 125 题牙科子集

教师：DeepSeek-V3、Doubao、Llama-3.3-70B、Qwen2.5-32B

硬件：NVIDIA H100 NVL 95GB，BF16 混合精度训练

论文回答的三个问题

如何让黑盒 API 教师也能提供有效蒸馏监督？
什么条件下学生模型不仅接近教师，而且可以超过教师？

真实 logprobs 与人工平滑标签在信息结构上差异有多大？

03 核心方法：Choice-Head 两阶段蒸馏

传统全词表蒸馏

151,936 维 logits
显存与计算代价高
API 教师难以支持

Choice-Head 蒸馏

只蒸馏 A/B/C/D/E
监督维度压缩到 5 维
天然兼容黑盒教师

Stage 1

Choice-Head KL + CE
1 epoch, $\alpha=0.35$
先学教师偏好结构

Stage 2

GT SFT 精校
2-5 epochs
用标准答案纠正教师误差

关键设计思想

Stage 1 : Choice-Head KL 蒸馏

仅提取 A/B/C/D/E 五个选项上的概率分布
损失: $\alpha \cdot \text{KL}(p_T // p_S) + (1-\alpha) \cdot \text{CE}$
典型显存约 22GB, 可使用 API-only 教师

Stage 2 : GT SFT 精校

继承 Stage 1 的 LoRA 权重
用标准答案对教师错误进行校准
对弱学生更稳定, 对 14B 强学生不一定持续增益

A. 基线建立

GT SFT 基线
7B : 77.11%
明确学生起点

B. 单教师蒸馏

白盒 Logit-KL
黑盒 Choice-Head
比较教师形态

C. 多教师优化

静态融合
一致性过滤
多数票集成

D. 范式拓展

CoT 蒸馏
 α - 散度
边界过滤

E. 容量升级

14B 学生
跨架构蒸馏
全量重分割

实验设计特点

从单教师到多教师、从 7B 到 14B、从 83 题到 991 题逐层推进
包含正例、负例与失败实验，不只保留最优结果
所有模块保留统一运行脚本，强调可复现性

关键可比性控制

模块之间尽量复用同一学生架构与训练超参
通过多 seed 与大测试集缓解 83 题小样本波动
把理论分析放在经验结论之后，避免先验解释
替代实证比较

DeepSeek-V3 教师

87.18%

991 题全量测试集准确率

14B 学生最佳

89.10%

Module 15 , seed 8

14B 三种子均值

88.67%

同样超过教师表现

参数压缩比

45×

671B 教师到 14B 学生

最重要的结论

学生模型不只是接近教师，而是在任务结构更对齐的训练目标下可以超过教师
对 14B 强学生而言，最有效的并不一定是更复杂流程，而是更精准的蒸馏目标
大测试集验证后，结论在统计上更稳健，不依赖少量题目的偶然波动

代表性结果串联

7B GT SFT 基线：77.11%
7B Choice-Head 蒸馏最佳：81.93%
14B DeepSeek 蒸馏最佳：84.34%（83 题牙科）
14B 全量重分割最佳：89.10%（991 题）

06 结果细化：什么条件下蒸馏有效？

白盒 vs 黑盒

白盒 Logit-KL：80.72%
黑盒 Choice-Head：81.93%
任务对齐优于全词表监督

Stage 2 的边界

7B 学生通常受益
14B 学生均值反而下降约 1.6pp
说明强学生会过校准

跨架构可行性

72.8% 的 Llama-70B 教师
仍能蒸馏出 87.25% 的 14B 学生
监督价值不只由教师准确率决定

结论不是“蒸馏越复杂越好”，而是“监督信号是否与任务决策结构匹配”。

因此，本文的主要价值不只是一组更高分数，而是给出了一套可解释的设计原则：聚焦选项空间、保留教师偏好、避免无效监督维度。

弱教师

代表：Kimi，61.45%
错误过多，噪声大
学生学习到的偏好不稳定

最佳区间

教师与 GT 不一致率约 5%–15%
既保留结构信息，又不过度偏离真值
是最适合迁移的蒸馏信号

过强教师

接近 one-hot
暗知识不足
难以提供有梯度价值的混淆结构

教师质量与蒸馏收益呈倒 U 型关系。真正关键的不是教师“绝对有多强”，而是它是否保留了可迁移的结构不确定性。

08 关键发现二：真实 logprobs 更有价值

为什么人工平滑标签不够？

人工平滑只在正确答案周围分配固定噪声，信息结构单一
无法反映“最容易混淆的错误项”与“边界距离”
因此在任务层面只提供了有限的软监督增益

信息几何分析给出的证据

Fisher-Rao 与 α -散度分析显示：真实 logprobs 更接近连续概率流形
真实标签的体积密度约为人工平滑标签的 2500 倍
这解释了为何真实 logprobs 教师往往蒸馏效果更稳定

结论：决定蒸馏效果的不只是“答对没有”，而是教师分布中是否保留了高价值的连续结构信息。

从论文到系统

仓库中已实现统一训练、评估、Web 推理与 Quiz 交互入口

7B/14B 学生模型可以在普通 GPU 条件下完成部署演示

适合患者教育、教学演示、标准化考试训练等轻量场景

方法本身也可迁移到其他标准化多选知识评测任务

应用意义

不是把大模型原样搬到端侧，而是围绕任务结构重构蒸馏目标

把“能答题”转化为“能低成本稳定交付”
为医疗大模型轻量化提供了可复现、可解释的实验范式

当前局限

任务仍以标准化选择题为主，尚未覆盖开放问答与长文本推理
教师谱系还不够密集，倒 U 型规律仍需更细粒度验证
评估指标以准确率为主，缺少人工质量评审与临床专家反馈
系统目前更多面向研究验证，而非直接临床部署

未来工作

扩大数据与多种子验证，进一步提高结论的统计置信度
研究教师路由、自适应 α - 散度与动态样本选择策略
从选择题扩展到开放医疗问答、多模态与真实交互任务
继续推进端侧部署与真实用户反馈闭环

结论与答辩总结

本文证明：当蒸馏目标与任务决策结构对齐时，小模型不仅能以更低成本部署，还有机会获得超过教师的任务表现。

感谢各位老师聆听，恳请批评指正。